

KALP ANOMALİLERİNİN DENETİMLİ ÖĞRENME İLE SINIFLANDIRILMASI

PTB-XL Data Grubu

Hazırlayanlar

İsim: Ibrahim H.I.

Soyisim: ABUSHAWISH

Numara: 0412230047

E-Posta: ibrahimh.i.a@ogr.iu.edu.tr

İsim: M. Yusuf

Soyisim: AYKUT

Numara:0414230024

E-Posta: m.aykut@ogr.iu.edu.tr

İsim: Samet

Soyisim: BATURAY

Numara:0414230028

E-Posta: baturay.samet@ogr.iu.edu.tr

İsim: Samet Ertuğrul

Soyisim: KURUM

Numara:0414230018

E-Posta: ertugrulsamet391@gmail.com

İÇİNDEKİLER

Sayfa No

İÇİNDEKİLER.....	2
1. GİRİŞ.....	3
2. LİTERATÜR ARAŞTIRMASI.....	3
3. YÖNTEM.....	6
3.1. Veri Setinin Tanımlanması ve Analizi.....	6
3.2. Ön İşleme.....	9
3.3. Öznitelik Seçimi.....	14
3.4. Model Seçimi ve Eğitim.....	16
3.5. Kodlama Ortamı.....	18
4. BULGULAR.....	19
5. TARTIŞMA VE SONUÇ.....	21
6. KAYNAKLAR.....	22
7. UYGULAMA.....	23

KALP ANOMALİLERİNİN DENETİMLİ ÖĞRENME İLE SINIFLANDIRILMASI

M. Yusuf Aykut, İbrahim Abushawish, Samet Ertuğrul Kurum, Samet Baturay

1. GİRİŞ

Elektrokardiyografi (EKG), kalp hastalıklarının erken ve doğru teşhisinde kritik önemlidir. EKG, kalbin ürettiği elektriksel sinyaller sayesinde aktivitesinin kaydedilmesini olanaklı kılar. EKG Sinyali kalbin aktivitesi ve morfolojik yapısına dair bilgiler içermektedir. Böylece kalpte miyokard, ritim veya iletim ile ilgili patolojilerin tespiti mümkün olur. Yakın gelecekte, klinik kullanımda yapay zeka ve makine öğrenmesi uygulamalarının pek çok hastalığın erken ve hızlı teşhisinde doktorlara yardımcı olarak kullanılması kaçınılmazdır ve bu alanda pek çok çalışma yapılmaya devam edilmektedir.

Bu çalışmanın amacı, EKG sinyalinden çıkarılan klinik olarak yorumlanabilir öznitelikleri kullanarak kalp anomalilerini tespit edebilen ve uygun olduğunda klinik ortama aktarılacak bir modelin ön çalışmasını gerçekleştirmektir. Bu kapsamda, PTB-XL+ veri setindeki median vuruşlar, fidüsyal noktalar ve süre/genlik tabanlı metrikler üzerinden denetimli öğrenme yöntemleri değerlendirilmiş; veri dengesizliği, eksik veri ve eşik belirleme gibi pratik klinik kısıtlar dikkate alınmıştır. Nihai hedef, sahada kullanılabilirliği artıracak biçimde sağlam, anlaşılabilir, genellenebilir ve doktorlara klinikte yardımcı bir tespit hattının temellerini atmaktır.

2. LİTERATÜR ARAŞTIRMASI

Literatürde hem klasik makine öğrenmesi hem de derin öğrenme modellerini kullanan çalışmalar bulunmaktadır. Bir çalışmada [1], PTB-XL veri setinde bulunan 5 adet üst sınıftan yalnızca hipertrofinin (HYP) bir alt sınıfı olan sol ventriküler hipertrofi tespitine odaklanılmıştır. Veri setinde 2181 adet sol ventriküler hipertrofi etiketli veri varken 9000 adet normal ECG verisi, Georgia ECG veri setiyle birlikte

değerlendirilmeye sokulmuştur. PTB-XL veri setinden özellikler araştırmacılar tarafından çıkarılmıştır ve Logistic Regresyon, Rastgele Ağaçlar(RF) ve Destek Vektör Makinesi (SVM) yöntemleri uygulanmıştır. RF ve SVM yöntemleri %87 üzerinde duyarlılık (sensitivity) ve özgüllük (specificity) sağlamıştır. EKG verilerinin ön işleme ve özellik çıkarım süreci genel olarak 4 adımdan oluşmuştur: Veri Seçimi ve Kalite Kontrolü, Feature Extraction, Sınıf Dengeleme ve Model Hazırlığı. Veri seçimi ve kalite kontrolü sürecinde PTB-XL ve Georgia 12-lead ECG veritabanları kullanılmıştır. Ham veriler üzerinde yalnızca "NORMAL" ve "LVH" olarak etiketlenmiş kayıtların işleme alınmasıyla etiketleme yapılmıştır. Kalitesiz veya yüksek gürültülü kayıtlar analize dahil edilmemiştir. Ayrıca EKG şablonu oluşturulurken ECGDeli paketi kullanılarak düşük sapmalı ve yeterli sayıda kalp vuruşu içermeyen sinyaller temizlenmiştir. Sinyaller temizlendikten sonra makinelerin öğrenebileceği üç ana kategoride özellikler türetilmiştir: Morfolojik özellikler, hermite dönüşümü, model türevli özellikler. Modelin çoğunluk sınıfı olan normal vakalara karşı taraflı olmasını engellemek için her bir eğitim aşamasında normal vakaların sayısı “downsampling” (daha fazla örneğe sahip olan sınıfı daha az olan sınıfın örnek sayısına indirerek veri azaltma) uygulanarak LVH vakalarıyla dengelenmiştir. Ancak bu veri kaybına yol açtığı için rastgele şekilde bu veri indirmeyi gerçekleştirdikleri 100 adet eğitim yapmışlar ve bu farklı eğitilmiş modellerin sonuçlarının ortalamasını çalışmanın metriği olarak sunmuşlardır (bkz. Ensemble Random Forest, SVM and LogReg modelleri). Çok fazla özelliğin modele dahil edilmesi karmaşıklığa ve “overfitting”e yol açabilir. SFFS yöntemi ile AUC skorunu en çok artıran özellikler seçilmiştir. En önemli 5 özellik kullanılarak "basitleştirilmiş" modeller (LogReg5, RF5, SVM5) kurulmuştur. Son olarak; çalışmada doğrulama yapmak için Monte Carlo, çapraz doğrulama ve dış doğrulama yapılmıştır. Veri seti %70 eğitim ve %30 test olarak bölünmüştür; bu işlem rastgele bölünmeden kaynaklanan hataları azaltmak için 5 kez tekrarlanmıştır. Hazırlanan modeller, eğitildikleri veri setinden tamamen bağımsız olan Georgia veritabanında test edilerek sağlamlıkları kanıtlanmıştır. Ön işleme ve özellik seçimi sayesinde SVM ve RF modelleriyle geleneksel klinik kriterlerinden %48 daha fazla hassasiyet (%86) ve %90'ın üzerinde doğruluk elde edilmiştir.

Yukarıda bahsedilen çalışmada sol ventrikül hipertrofisi (LVH) ele alınırken başka bir çalışmada [2], akut miyokard enfarktüsü'ne (MI) odaklanılmıştır. EKG

sinyalinden çıkarılan öznitelikler kullanılarak eğitilen klasik makine öğrenmesi modelleri ile ham sinyal verisinin doğrudan konvolüsyonel sinir ağlarına beslenmesiyle oluşturulan derin öğrenme modellerinin performansları karşılaştırılmıştır. Bu çalışmada 6 klasik makine öğrenimi modeli, eğitim için kullanılmıştır: KNN, SVM, Random Forest, XGBoost, Decision Tree, Gaussian Naive Bayes. Eksik verilerin giderilmesi için scikit-learn kütüphanesinde yer alan Simple Imputer yöntemi uygulanmıştır. Random Forest ve Decision Tree haricindeki modeller için de Standard Scaler kullanılmıştır. Bunun sebebi ağaç tabanlı modellerin ölçek duyarsız olmasıdır. Ağaçlar ayrımı eşikler üzerinden tanımlar. Bu nedenle ölçeklendirme uygulanmamıştır. Çalışmada PTB-XL'den sadece NORM ve MI etiketli, 100 Hz örnekleme 12-lead ECG'ler alınmıştır. Veri, MI örnekleri referans alınarak 70/15/15 (train/val/test) bölünmüştür. Eğitim seti iki sınıfta dengelenmiştir; validasyon ve test ise orijinal dağılımı korumuştur. Ortalama doğruluk oranında en yüksek model %89 doğruluk oranı ile XGBoost olmuştur. Modelinin duyarlılığı ve özgüllüğü de %88 olarak ölçülmüştür. Bu modelin ardından %88 doğruluk oranı ile SVM ve RandomForest modelleri gelmektedir.

Diğer bir çalışmada [3], PhysioNet/Computing in Cardiology (CinC) 2020 yarışmasında verilen 12-lead ECG verilerini kullanarak sinyalden çıkarılan öznitelikler ile XGBoost modeli kullanılarak sınıflandırma yapılmıştır. Çalışmada, çoklu etiket problemini çözmek için tüm etiketlere tek bir model oluşturmak yerine; yarışmadaki hastalık sınıflarının her biri için ayrı binary XGBoost modeli eğitilmiştir. Sınıf dengesizliğini çözmek için de -undersampling- çoğunluk sınıfı rastgele azaltılarak sınıflar eşitlenmişlerdir. Bu yaklaşımın neden olabileceği veri kaybını en aza indirmek ve sonuçları sağlamlaştırmak için de K-fold cross validation yöntemi kullanılmıştır: Bir kez train/test yapmak yerine veri n parçaya bölünüp n kez dönüşümlü kullanılmıştır. Modelin ürettiği olasılık değerinin 0.9 eşik değerini geçme şartı konulmuş ve bazı durumlarda bu eşik her hastalık için özel olarak ayarlanmıştır. Çalışmayı yapan ekip, bu yöntemle 0.155 Challenge Skoru elde etmiş ve yarışmada sıralamaya giren 41 takım arasından 24. sırada yer almıştır.

3. YÖNTEM

3.1. Veri Setinin Tanımlanması ve Analizi

PTB-XL+, PTB-XL'in [4] 12-lead ECG dalga formlarından üç farklı analiz aracının (GE Marquette 12SL, University of Glasgow Uni-G ve açık kaynak ECGDeli) çıkardığı öznitelikleri, median vuruşları ve fidüsyal noktaları içeren tamamlayıcı bir veri setidir. Öznitelikler; süreler, genlikler, segment başlangıç/bitişleri ve alanlar (Uni-G'de vektörkardiyografik ölçümler dahil) gibi klinik olarak yorumlanabilir tanımlayıcıları kapsar. Veri seti ayrıca 12SL'nin otomatik tanı ifadelerini ve hem 12SL hem de PTB-XL etiketlerinin SNOMED CT'ye eşlenmiş sürümlerini sağlar; böylece modellerin klinisyen etiketleri ile otomatik ifadeler arasında karşılaştırmalı olarak eğitilip değerlendirilebilmesine olanak tanır [5].

PTB-XL veri setinin demografik ve tanısal özellikleri, Figür 1'de görselleştirilmiştir. Yaş bakımından 40-80 yaş aralığında yoğunlaşan ve ortalama 62.8 yıl olan bir hasta popülasyonunu temsil etmektedir. Hastaların %52.1'si erkekler oluştururken %47.9'i kadınlar oluşturmaktadır, Ortalama kilo 71.0 KG, Ortalama yaş 62.8'dir (Std: 32.3), Ortalama boy ise 166.7 cm'dir. bunlar demografik bilgiler olarak yer almıştır.

Eksik değerlerde hem demografik verilerden hem de EKG sinyal verilerinden eksikler bulunmaktadır. Ancak bu verilerin çoğunluğu demografik verilerdeki eksikliklerdir. EKG sinyalinden çıkarılan özniteliklerden 6 adedindeki eksiklik örneklerin %10'undan azken geri kalan özniteliklerde eksik verilerin miktarı %5'ten azdır.

PTB-XL veri seti, 18869 farklı hastadan 10 saniye uzunluklarla toplanan 21799 klinik 12 kanallı EKG kaydı içermektedir. Dalga dosyalarının 500 Hz ve 100 Hz sürümleri mevcuttur. Bu kayıtlardan 9514 adedi normal (sağlıklı) EKG iken, 12285 adedi hastalıklıdır.

Veri setinin pandas kütüphanesindeki info() ve describe() fonksiyonlarının çıktıları verilmiştir.

```
<class 'pandas.core.frame.DataFrame'>
Index: 21388 entries, 1 to 21837
Columns: 793 entries, patient_id to HYP
dtypes: float64(750), int64(42), object(1)
memory usage: 129.5 MB
```

	count	mean	std	min	25%	50%	75%	max
patient_id	21388.0	11179.3	6386.3	1.0	5657.8	11229.5	16768.2	22207.0
age	21388.0	59.8	16.9	0.0	50.0	62.0	72.0	95.0
sex	21388.0	0.5	0.5	0.0	0.0	1.0	1.0	1.0
strat_fold	21388.0	5.5	2.9	1.0	3.0	6.0	8.0	10.0
P_OnsAmp_I	21388.0	0.0	0.0	-0.2	0.0	0.0	0.0	0.5
P_Amp_I	21388.0	0.1	0.1	-0.3	0.0	0.1	0.1	0.7
P_Dur_I	21388.0	62.9	39.8	0.0	34.0	74.0	96.0	202.0
Q_PeakTime_I	21388.0	5.6	6.6	0.0	0.0	0.0	10.0	84.0
R_Area_I	21388.0	1.1	0.7	0.0	0.6	0.9	1.3	7.8
R_PeakTime_I	21388.0	40.9	9.7	0.0	36.0	40.0	44.0	152.0

Tablo 1. Veri Setine dair İstatistiksel değerler

EKG kayıtları 5 farklı üst sınıfta kategorileşmiştir. **Normal EKG**(%43), **Miyokard Enfarktüsü** (%25), **ST/T Değişikliği** (%24), **İletim Bozukluğu** (%22), **Hipertrofi** (%12) şeklinde dağılıma sahiptir. Bir kayıt birden fazla anomali tanısı alabilmektedir.


Class	Name	Count	Percentage
NORM	Normal ECG	9,514	44.5%
MI	Myocardial Infarction	5,424	25.4%
STTC	ST/T Change	2,817	13.2%
CD	Conduction Disturbance	2,325	10.9%
HYP	Hypertrophy	1,308	6.1%

Tablo 2. Sınıf Dağılımları

Sınıfların dağılımı incelendiğinde veri setinde belirgin bir sınıf dengesizliği olduğu görülmektedir. Normal EKG veri setinin yaklaşık yarısını oluştururken,

Hipertrofi örneklerin yalnızca %12'sinde var olarak etiketlenmiştir. Bu durum, makine öğrenmesi modellerinin eğitim aşamasında normal EKG verilerini daha iyi öğrenirken, hipertrofi gibi az örneğe sahip sınıfların öğrenememesine sebep olabilir. Bu veri dengesizliği ön işleme, eğitim ve test aşamalarında doğru anlaşılmaz ve önlem alınmazsa modelde gerçeği yansıtmayan başarımlerle karşılaşılabilir.

Bu dengesizlik problemi ve çok etiketli yapının getirdiği zorluklar, Ön İşleme bölümünde ele alınacaktır. Sınıf dengesizliğini gidermek için ağırlıklı kayıp fonksiyonları (weighted loss), aşırı/eksik örnekleme (oversampling/undersampling) teknikleri ve stratejik veri artırma (data augmentation) yöntemleri değerlendirilecektir.



Figür 1. İlk 10 özneliğin eksik örnek yüzdeliğini gösteren grafik.

Tablo 3'te her tanı sınıfı için Isolation Forest yöntemiyle aykırı değer analizi yapılmıştır. Her sınıf için %3.3-7.2 oranında aykırı değer tespit edilmiştir.

Isolation Forest yöntemi, rastgele ağaçlar kullanarak örneklerin izolasyon zorluğunu ölçer. Yöntem, her örneğin normal veri noktalarından ne kadar kolay izole edilebildiğini hesaplayarak bir anomali skoru üretir. Düşük skorlu örnekler (daha kolay izole edilebilenler)

aykırı değer olarak işaretlenir. Yöntem, contamination parametresini 'auto' olarak ayarlayarak veri dağılımına göre otomatik olarak threshold belirler. Bu yaklaşım, yüksek boyutlu veri setlerinde etkili olduğu kanıtlanmış bir yöntemdir.

Label	Toplam	Outliers	Yüzde
NORM	7,596	251	3.30%
MI	4,379	266	6.07%
STTC	4,186	268	6.40%
CD	3,907	280	7.17%
HYP	2,119	118	5.57%

Tablo 3. Aykırı Değer Oranları


3.2. Ön İşleme

Ön işleme, model eğitilmeden önce hedef değişkenin belirlenmesinde önemli olacak özniteliklere göre verilerin, normalizasyonunu, standardizasyonunu, eksik veri doldurma ya da eksik/aykırı veri çıkarmayı, veri dönüşümünü, öznitelik çıkarımı ve öznitelik seçimi gibi aşamaları içerir. Bu aşamaların probleme göre mantıklı ve açıklanabilir olduğu durumda uygulanması beklenir. Bu çalışmada yapılan ön işleme aşamaları adım adım açıklanmaktadır.

Başlangıç olarak PTB-XL veri setinde klinik üst bilgileri içeren veritabanı dosyası ile EKG sinyallerinden çıkarılan 12-lead özellikleri barındıran veri dosyası **ecg_id** anahtarı kullanılarak birleştirilmiştir. Ardından, her bir kaydın tanı etiketleri, SCP-ECG standartlarına göre tanımlanmış 5 ana teşhis sınıfına (Normal, MI, ST/T Değişikliği, İletim Bozukluğu, Hipertrofi) dönüştürülmüştür. Bu dönüşüm sonucunda, herhangi bir tanı sınıfına girmeyen veya etiketi bulunmayan 411 kayıt tespit edilerek analiz dışı bırakılmış ve çalışma seti örnek sayısı 21,388 kayıt olarak güncellenmiştir.

Demografik veriler: Hastaların boy (height) bilgisinde %67.65 ve kilo (weight) bilgisinde %56.21 oranında eksiklik bulunmaktadır. Bu değişkenlerdeki yüksek eksiklik oranından dolayı model eğitiminde kullanılmamıştır ve veriden çıkarılmıştır.

EKG verisi: T_AxisFront_Global ve R_AxisFrontal_Global etiketlerinde toplam 5 adet örneğin verisi eksiktir, bunlar silinmiştir. **P_On_Global, P_Off_Global, P_Dur_Global, P_AxisFront_Global, PR_Int_Global, HR_Atrial_Global,** Öznitelikleri yaklaşık %8 eksik veri barındırmaktadır. Bu eksikliklerin çoğu P dalgasında bulunmaktadır ve bu durum atriyal fibrilasyon gibi P dalgasının görülmediği veya belirsiz olduğu durumlardan kaynaklanıyor olabilir. Dolayısıyla bu verilere medyan imputasyon uygulamanın yanı sıra, eksik veri barındıran örneklerle ikili (binary) bayrak eklenmiştir.



Figür 2. Eksik Veri İçeren Kayıtların Dağılımı

Satır bazlı eksik veri analizi, veri setindeki satırların yalnızca çok küçük bir bölümünde anlamlı eksiklik olduğu gösterilmiştir; maksimum satır bazlı eksiklik oranı %0,9 olup, %10'dan fazla eksik değere sahip hiçbir satır bulunmamıştır. Bu nedenle satır silme işlemi uygulanmamıştır ve veri setinin bütünlüğü korunmuştur. Satır silme işlemi sadece hedef değişkeni ("label" etiketi) olmayan verilerde uygulanmıştır.

heart_axis, PTB-XL'de kalp eksenini LAD/RAD/ALAD gibi kaba ve rapor temelli bir kategori olarak verir. Bu projede ise 12SL dosyasında QRS/P/T eksenleri ve morfolojiler ayrıntılı, sayısal (sürekli) feature'lar olarak zaten mevcut. Bu yüzden heart_axis hem bu bilgiyi tekrarlar (redundant) hem de daha az bilgi taşır ve rapor

kaynaklı gürültü içerebilir. Ayrıca tek bir kategorik sütun için özel encoding ve pipeline ek yükü getirir; beklenen katkı da belirsizdir. Bilimsel ve pratik nedenlerle, eksen bilgisi zengin sayısal özelliklerle sağlandığından heart_axis kullanılmamıştır. Benzer şekilde, ağırlık ve boy da çok fazla sayıda eksik veri barındırdığından modele dahil edilmemiştir.

Benzer gerekçelerle, PTB-XL metadata tablosundaki diğer rapor ve sistem kaynaklı öznitelikler (örneğin ham tanı kodlarını içeren **scp_codes**, serbest metin rapor alanları, cihaz/merkez bilgileri ve gürültü/artefakt etiketleri) de modelin giriş uzayına dahil edilmemiştir. Bu çalışmada giriş özellikleri, ağırlıklı olarak PTB-XL+12SL dosyasından elde edilen sayısal ECG ölçümleri ile sınırlandırılmıştır. Böylece model, tanı etiketine çok yakın veya rapor temelli özetlerden ziyade, doğrudan sinyalden otomatik çıkarılmış nicel bilgiyi öğrenmeye odaklanmaktadır ve gereksiz bilgi sunulmamaktadır.

Eksik veri kalıplarının rastgele dağılmadığı gözlenmiştir. Özellikle P dalgası ile ilişkili P_On_Global, P_Dur_Global gibi özniteliklerin eksik olduğu örneklerde, **MI (%41–42)** ve **STTC (%58–60)** tanıların anlamlı biçimde daha sık görülmektedir. Bu gözlem, eksik verinin yalnızca teknik değil, **anlam taşıyan klinik bir işaret** olabileceğini düşündürmektedir, bu açıdan eksiklik MNAR olarak sınıflandırılabilir [6].

Bu nedenle, bu öznitelikler için medyanla doldurma ile beraber; aynı zamanda is_missing_ÖZNITELIK şeklinde **P_On_Global**, **P_Off_Global**, **P_Dur_Global**, **P_AxisFront_Global**, **PR_Int_Global**, **HR_Atrial_Global**, öznitelikleri için **eksiklik bayrakları** da modele dahil edilmiştir. Bu sayede model, eksikliği bir bilgi kaybı olarak değil, potansiyel bir **kalp ritim anomalisi işareti** olarak değerlendirilecektir.

Öte yandan, **heart_axis** gibi dış kaynaklı ve %38 oranında eksik olan bazı özellikler, hem klinik belirsizlik hem de modelleme açısından sınırlı katkı taşıdığı için giriş uzayından çıkarılmıştır.

Eksikliği yalnızca birkaç örnekte gözlenen T_AxisFront_Global ve R_AxisFrontal_Global öznitelikleri silinmiştir.

Öznitelik Grubu	Uygulanan Yöntem	Gerekçe
P Dalgası Öznitelikleri(<i>P_On</i> , <i>P_Off</i> , <i>P_Dur</i> , <i>PR_Int</i> , <i>HR_Atrial</i> , <i>P_Axis</i>)	Sabit Değer (0.0)+ is_missing Bayrağı	Bu özniteliklerin eksikliği teknik bir hata değil, P dalgasının oluşmadığı (örn. Atrial Fibrilasyon) fizyolojik bir durumu işaret etmektedir. Her öznitelikte ortalama % 7 oranında eksik değer vardır
Diğer Sayısal Öznitelikler(örn. <i>R_Axis</i> , <i>T_Axis</i>)	Eğitim Seti Medyanı+ is_missing Bayrağı	Veri dağılımını korumak ve ortalamayı saptırabilecek aykırı değerlerden (outliers) kaçınmak için medyan tercih edilmiştir.
Kalp Ekseni(<i>heart_axis</i>)	Sütun Silindi	%38 eksiklik oranı doldurma yapmak için fazla yüksektir.

Tablo 4. Eksik Verilere Uygulanan Yöntemler

"Eksikliği, fizyolojik bozulmayı temsil eden bazı öznitelikler (örneğin P dalgası) için 0.0 atanarak 'yokluk' kodlandı. Bu değerler, bayraklarla birlikte modele verilerek sinyal kaybı bilgisi korunmuştur."

Amputasyon (imputation) yapmadan önce klasik bilgi sızıntılarını önlemek için train set veri seti öğrenme (train), kontrol (validation) ve test kümelerine ayrılmıştır. Bunun olmaması durumunda, bir doldurma işlemi yapılırken alınan ortalama (mean) değer bütün veri setinin ortalama değeri olacaktır, bu eğitim verisinde klasik bir sızıntı (leak) olarak tanınmaktadır çünkü bütün veri setine ait ortalama bilgisi bütün kümelede dağıtılmış olacaktır. Buna binaen, bu çalışmada veri sızıntısı problemine dikkat edilmiştir [7]. Kümeleme oranları aşağıdaki gibidir:

- Eğitim (Train): 17084 samples (%79.9)
- Kontrol (Val): 2146 samples (%10.0)
- Test: 2158 samples (%10.1)


Amputasyon işlemi sadece Eğitim veri setinin üzerinde uygulanmıştır, hali hazırda fit edilmiş imputer, kontrol ve test veri setleri için de uygulanmıştır. bu çalışmada kullanılan basit imputer median değeridir. Bu işlemten önce kayıp değerler eğitim seti için 41455, kontrol seti için 4974, test seti için ise 5019'dur. İşlem sonrası bütün kümelede kayıp değerler sıfıra indirgenmiştir.

Benzer şekilde sadece Eğitim kümesi üzerinde ölçekleme modeli geliştirilmiş, daha sonra diğer kümeler için uygulanmıştır. Ölçekleme yapılırken eğitim veri setinin her sayısal özelliği standardize edilmiştir. `StandardScaler()` fonksiyonunu kullanarak her sütun için ortalaması (μ) ve standart sapması (σ) hesaplanıp aşağıdaki formülle dönüşümü yapıyor:

$$x = \frac{(x - \mu)}{\sigma} \quad (1)$$

ve bu sayede ortalaması ~ 0.0 , standart sapması ~ 1.0 yapılması hedeflenmiştir. daha sonra aynı ölçekle yeni doğrulama seti ve test seti için ayrı olarak kullanıldı. Bu işlem sonucunda elde edilen değerler 10^{-3} mertebesinde nümerik tolerans içindedir ve ölçekleme tutarlıdır. Model seçimi aşamasında Random Forest kullanılacaktır ve ölçekten çok fazla etkilenmeyen bir model olarak bilinir. “Random Forest ölçek duyarsız olsa da, özniteliklerin ortak ölçekte tutulması ve olası model genişletmelerine (örn. SVM/lojistik) uyum için sayısal sütunlara `StandardScaler` uygulanmıştır. İkili eksiklik bayrakları ölçekleme dışı bırakılmıştır.

Bahsi geçen işlemler neticesinde kümeler içindeki sınıf dağılımları Figür 2’de gösterilmiştir.



Figür 3. Splitlere Göre Sınıf Dağılımı.

Figür 3’teki dağılımlara bakıldığında sınıf dengesizliği olduğu gözlemlenmektedir. Bu durum modelin eğitim aşamasında veride daha baskın olan sınıfı daha iyi öğrenirken azınlık sınıftaki veriyi daha kötü öğrenmesine yol açabilir. Eğer aynı dengesizlik

durumu test setinde de mevcut ise sonuç metrikler gerçeği yansıtmayabilir ve şişebilir. Bu durumun çözümü olarak, sınıfları ağırlıklandırmak ve random downsampling yöntemleri uygulanmıştır.

Bu çalışmada, tespit edilen aykırı değerlere müdahale edilmemiştir, herhangi bir silme ya da değişiklik yapılmamıştır. Bu kararın temel gerekçesi, tıbbi veri setlerinde aykırı değerlerin gerçek klinik varyasyonları veya nadir görülen hastalık alt tiplerini temsil edebilmesidir. Özellikle kardiyovasküler hastalıklar gibi heterojen popülasyonlarda, bu tür örnekler modelin genelleme yeteneğini artırabilir. Ayrıca, yüksek boyutlu öznitelik uzaylarında aykırı değer tespitinin belirsizlik içerebileceği göz önüne alındığında, konservatif bir yaklaşım olarak tüm veriyi korumak tercih edilmiştir.

Özet olarak bu çalışmada PTB-XL veri seti için uygulanan ön işleme hattı, veri kalitesini artırmak ve veri sızıntısını önlemek amacıyla tasarlanmıştır. Etiket eksik olan ve özelliklerinin büyük kısmı boş olan kayıtlar çıkarılmış, boy ve kilodan türetilen BMI ile P-dalgası ile ilişkili eksiklik paternlerini yakalayan ikili “missing indicator” değişkenleri eklenmiştir. Ardından veri, strat_fold etiketine göre eğitim, doğrulama ve test kümelerine ayrılmış; medyan imputasyon ve standartlaştırma yalnızca eğitim kümesi üzerinde fit edilerek aynı dönüşümler doğrulama ve test kümelerine uygulanmıştır. Son olarak, dengesiz sınıf dağılımını dengelemek üzere sınıf ağırlıkları yalnızca eğitim verisi üzerinden hesaplanmış ve azınlık sınıfların modele katkısı artırılmıştır.


3.3. Öznitelik Seçimi

Çalışmamızda, öznitelik seçimi aşamasında varyans eşikleme ve rastgele orman ‘random forest’ yöntemleri uygulanmıştır. Bu yöntemler dışında kullanılabilecek **Temel Bileşen Analizi (PCA)** [8], **SelectKBest / mutual information**, **L1 tabanlı (Lasso) regularizasyon**, **Recursive Feature Elimination (RFE)**, gibi teknikler bulunmaktadır.

İlk olarak, **Variance Threshold** yöntemiyle varyansı çok düşük olan, büyük ölçüde sabit ve bilgi taşımayan öznitelikler elenmiştir. Bu adım, hem gereksiz özellikleri azaltmış hem de veri gürültüsünü düşürmüştür.

Ardından, **Random Forest tabanlı öznitelik önem sıralaması** uygulanarak, sınıf etiketlerini ayırt etmede yüksek katkı sağlayan öznitelikler seçilmiştir. Random Forest algoritması, nonlineer ilişkileri yakalayabilme kabiliyeti ve yorumlanabilir skor üretmesi açısından literatürde de tercih edilesi bir yöntem olmuştur [9].

Şekil X'te, özelliklerin varyans değerlerinin 0–1 aralığındaki dağılımı gösterilmiştir. Varyansı 0.05'in altında kalan öznitelikler, sabite yakın oldukları ve sınıflar arası ayırt ediciliği zayıf olduğu için çıkarılmıştır. Görselde de görüldüğü üzere, büyük çoğunluk bu eşik civarında yoğunlaşmakta olup, **toplam 793 öznitelikten 186 tanesi** bu eşik nedeniyle elenmiştir. Böylece bilgi katkısı sınırlı, durağan öznitelikler modelleme dışına alınmıştır.




Figür 4. Varyans eşikleme

RandomForestClassifier modeli, öznitelik önemini her ağacın bölünme (split) noktalarında kullanılan özniteliklerin sağladığı bilgi kazancı üzerinden hesaplanmaktadır. Her öznitelik, karar ağaçlarında ne kadar sıklıkla ve ne kadar erken seviyelerde kullanılıyorsa, sınıf ayırımına o kadar katkı sağladığı kabul edilir. Bu bağlamda:

- Her bir ağacın oluşturulmasında kullanılan veri alt kümesi üzerinden, **Gini impurity** veya **entropi** gibi safsızlık metrikleri kullanılarak, özneliliğin sağladığı toplam bilgi kazancı hesaplanır.
- Tüm ağaçlardaki katkılar toplanır ve normalleştirilerek "**importance score**" elde edilir [10].

- Elde edilen bu skorlar, öznitelikleri en etkili olandan en az katkı yapanlara doğru sıralamamıza olanak tanır.

Bu çalışmada, `sklearn.ensemble.RandomForestClassifier` sınıfı 250 ağaç (`n_estimators=250`) ve maksimum 12 derinlik (`max_depth=12`) ile eğitilmiş; eğitim verisinin tamamı üzerinden bu önem skorları hesaplanmıştır. En yüksek skoru alan 50, 100 ve 200 öznitelik, sırasıyla üç farklı model varyasyonu için kullanılmıştır. Figür 5’da en önemli 30 özniteliğe ait skorlar görselleştirilmiştir.



Figür 5. Top 30 Özniteliliğin Önem Sırası

3.4. Model Seçimi ve Eğitim

Bu çalışmada sınıflandırma modeli olarak **Random Forest (RF)** ve sonuçların karşılaştırılması amacıyla literatürde sıkça kullanılan **Support vector machine SVM** tercih edilmiştir. RF; çok sayıda karar ağacını topluluk (ensemble) yaklaşımıyla birleştirerek daha kararlı ve genellenebilir tahminler üretir. PTB-XL+ gibi yüksek boyutlu ve klinik olarak yorumlanabilir öznitelikler içeren veri setlerinde RF’nin tercih edilmesinin başlıca nedenleri şunlardır: (i) nonlineer ilişkileri yakalayabilmesi, (ii) yüksek boyutlu uzaylarda güçlü performans göstermesi, (iii) ölçeklemeye görece daha az duyarlı olması ve (iv) öznitelik önem skorları üzerinden yorumlanabilirlik sunması.

Karşılaştırma modeli olarak tercih edilen **SVM** ise, özellikle yüksek boyutlu özellik uzaylarında **margin maksimizasyonu** prensibiyle çalışması ve **RBF (Radyal Tabanlı Fonksiyon) çekirdeği** kullanarak doğrusal olmayan ilişkileri başarılı bir şekilde ayırabilmesi nedeniyle seçilmiştir. SVM'nin bu yapısı, yüksek boyutlu, sayısal EKG öznitelik setimizin yapısına güçlü bir alternatif sunarak, ağaç tabanlı (RF) modelin sonuçlarının **sınır belirleme** yeteneği açısından doğrulanmasına olanak tanımıştır.

Modelin temel hiper parametreleri aşağıdaki şekilde sabitlenmiştir:

- `n_estimators = 250`
- `max_depth = 12`
- `random_state = 42`
- `n_jobs = -1`

Modelin temel hiper-parametre seçiminde, çalışmanın bu aşaması için **sağlam ve genellenebilir bir başlangıç modeli** oluşturmak hedeflenmiştir. Bu doğrultuda, ağaç sayısı (`n_estimators = 250`) ve maksimum derinlik (`max_depth = 12`) değerleri, PTB-XL gibi yüksek boyutlu klinik öznitelik setlerinde yaygın olarak kullanılan, aşırı uyumu (overfitting) makul bir düzeyde tutarken yeterli ayırım gücü sağlayan değerler olarak belirlenmiştir. Ayrıca, `random_state = 42` sabitlemesi, deney sonuçlarının tam tekrarlanabilirliğini garanti altına almaktadır.

Öznitelik seçimi aşamasında elde edilen **Top-50 / Top-100 / Top-200** öznitelik alt kümeleri ile RF modelleri ayrı ayrı eğitilmiş ve performansları karşılaştırılmıştır. Böylece özellik sayısının model başarımına ve aşırı uyuma (overfitting) etkisi kontrollü biçimde incelenmiştir.

Sınıf Dengesizliği Deney Tasarımı

PTB-XL veri setinde sınıflar arasında belirgin dengesizlik bulunduğundan, eğitim aşamasında iki farklı yaklaşım değerlendirilmiştir: **class weight** [11] ve **undersampling** [12]. Bu kapsamda toplam **4 senaryo** tasarlanmıştır:

- **CW-50 / CW-100 / CW-200:**
`class_weight="balanced"` kullanılarak, Top-50 / Top-100 / Top-200

öznitelik setleriyle **3 ayrı Random Forest modeli** ve bir adet SVM CW-200 modeli eğitilmiştir. Burada amaç, veri kaybına yol açmadan (örnek silmeden) azınlık sınıfların kayıp fonksiyonundaki etkisini artırmaktır.

- **US-200 (Undersampling):**


Top-200 öznitelik seti sabit tutularak, yalnızca eğitim kümesi üzerinde rastgele eksik örnekleme (undersampling) uygulanmıştır. Bu yaklaşım, çoğunluk sınıf örneklerinin rastgele azaltılmasından kaynaklanabilecek potansiyel bilgi kaybını en aza indirmek ve sonuçların sağlamlığını artırmak için bir Topluluk (Ensemble) yapısıyla birleştirilmiştir. Bu kapsamda, 50 farklı rastgele undersampling kümesi oluşturulmuş ve her biriyle ayrı bir Random Forest modeli eğitilmiştir. Nihai tahminler, bu 50 modelin olasılık skorlarının ortalaması alınarak (soft voting) elde edilmiştir. Validasyon ve test kümeleri ise orijinal sınıf dağılımını koruyarak bırakılmış; böylece karşılaştırma adil ve veri sızıntısı olmadan yapılmıştır.

Bu kurgu ile aynı model (RF) altında yalnızca iki değişkenin etkisi izlenebilmektedir:

1. öznitelik sayısı (Top-50/100/200)
2. dengesizlik giderme stratejisi (class weight vs undersampling).

Model olasılıksal sonuçlar üretmektedir ve bir vaka için birden fazla tanı koyulabilmektedir. Dolayısıyla bir olasılıksal sonucun, o etiket için pozitif ya da negatif olarak adlandırılacağını belirlemek için bir eşik (threshold) belirlemek gerekir.

Class-Weight Yaklaşımı: Sınıf Dağılımı ve Ağırlıklar



Figür 7. Class Weight oranları

En etkili eşiği belirlemek için 0.01 aralıklarla en yüksek F1 skoru sağlayan eşik seçilmiştir. Problem spesifik olarak recall ya da precision değerinin maksimize olduğu eşik değerini de seçmek düşünülebilir.

Değinildiği üzere karşılaştırma yapmak için SVM modeli de denenmiştir. SVM margin maximization prensibiyle çalışır. RBF kernel ile veri yüksek boyutlu özellik uzayına dönüştürülür. SVM bu yüzden yüksek boyutlu özniteliğe sahip veri setlerinde etkilidir. Multi-label sınıflandırma için One-vs-Rest yaklaşımı kullanılır.

3.5. Kodlama ortamı

Bu çalışma kapsamında tüm veri hazırlama, görselleştirme ve modelleme adımları Python 3 (çalışma sırasında Python 3.11+) ile gerçekleştirilmiştir. Deneylerde kullanılan temel kütüphaneler; veri işleme için pandas ve numpy, modelleme ve değerlendirme için scikit-learn, görselleştirme için matplotlib ve seaborn olarak belirlenmiştir. Bağımlılıklar proje kökündeki requirements.txt dosyasında merkezi olarak tanımlanmış; böylece ortamın yeniden kurulumu ve sürüm uyumluluğu standartlaştırılmıştır.

Deney akışı modüler betikler üzerinden yürütülmüştür: veri ön işleme hattı preprocessing/pipeline.py, öznitelik seçimi preprocessing/feature_selection.py, figür üretimi figures/generate_figures.py ve model eğitimi/değerlendirmesi training/train_models.py ile gerçekleştirilmiştir.

Proje dizin yapısı, tekrarlanabilirliği destekleyecek şekilde veri-kod-çıktı ayrımını açıkça kurmaktadır: ham veri kaynakları ptb-xl/ ve ptb-xl+/ altında tutulurken, deneylerde kullanılan ara/nihai tablolar data/processed/ altında sürümlenebilir dosyalar olarak saklanmaktadır. Keşifsel analiz betikleri eda/, figür üretimi figures/, ön işleme ve öznitelik seçimi adımları preprocessing/, model eğitim ve değerlendirme akışı ise training/ dizinlerinde konumlandırılmıştır. Üretilen

performans özetleri ve sınıf bazlı metrikler `results/` altında biriktirilerek, raporlanan bulguların doğrudan yeniden üretilebilir artefaktlar üzerinden izlenmesi sağlanmıştır.

Kod, betikler ve deney çıktıları sürüm kontrolü altında tutulmuş ve kamuya açık olarak paylaşılmıştır¹.

Deneylerin yeniden çalıştırılmasına yönelik temel adımlar `README.md` dosyasında açıklanmıştır.

4. BULGULAR

Model	Accuracy	Precision	Recall	F1 Score	ROC-AUC
RF + Top-50 CW	%55.33	%67.64	%76.53	%71.53	0.904
RF + Top-100 CW	%58.43	%71.29	%73.68	%72.39	0.909
RF + Top-200 CW	%58.85	%71.30	%75.60	%73.21	0.915
RF + Top-200 + Ensemble	%54.49	%68.41	%78.59	%72.28	0.915

Tablo 5. Modellerin eğitim metrikleri


Tablo 5'e göre öznitelik sayısı arttıkça performans genel olarak yükseliyor. Top-50'den Top-200'e geçince **Accuracy %55.33 → %58.85**, **F1 %71.53 → %73.21** ve **ROC-AUC 0.904 → 0.915** seviyesine çıkıyor. Bu, daha fazla seçilmiş özniteliğin sınıfları ayırmada fayda sağladığını gösteriyor. Undersampling uyguladığımız, Ensemble yaklaşımı **Recall'ı artırıyor (%75.60 → %78.59)**; ancak Precision ve Accuracy'de düşüş görüldüğü için toplam F1'de belirgin bir kazanç oluşturmuyor.

¹ <https://github.com/AykutN/PTB-XL-Heart-Anomaly-Diagnosis-Project>

Sınıf	Eşik Değeri	Precision	Recall	F1
NORM	0.30	%79.27	%92.11	%85.21
MI	0.45	%74.91	%72.73	%73.80
STTC	0.46	%69.24	%79.08	%73.84
CD	0.45	%76.87	%70.36	%73.47
HYP	0.43	%56.23	%63.74	%63.74

Tablo 6. RF tabanlı CW-200 modelinin Sınıfların eşikleri

Tablo 5'te CW-200 modeli için her sınıfa özel eşikler verilmiştir. NORM sınıfında **Recall %92.11** ile en yüksek; yani normal örneklerin büyük kısmı doğru yakalanıyor. MI ve STTC sınıflarında F1 değerleri **~%74** civarında ve dengeli bir başarı var. En zor sınıf HYP: **Precision %56.23, F1 %63.74**. Bu durum, hipertrofi örüntülerinin diğer sınıflarla daha çok örtüşebildiğini ve ayrımın daha zor olduğunu gösteriyor.



Figür 8. Sınıfların ROC-AUC eğrisi

ROC eğrileri modelin sınıfları ayırma gücünün yüksek olduğunu gösteriyor. AUC değerleri NORM **0.938**, MI **0.923**, STTC **0.929**, CD **0.901** ve HYP **0.883**. HYP

diğerlerine göre daha düşük kalsa da tüm sınıflarda AUC'nin **0.88+** olması, modelin genel ayırıştırma kapasitesinin güçlü olduğunun göstergesidir.

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
SVM	%59	%71.1	%79	%74.6	0.922
RF + Top-200	%58.85	%71.30	%75.60	%73.21	0.915

Tablo 7. SVM ve Random Forest modellerinin Top 200 CW karşılaştırmaları

- **SVM**, genel Accuracy (%59.00) ve Precision (%71.10) metriklerinde RF'e yakın bir performans sergilemesine rağmen, daha kritik olan **Recall (Geri Çağırma)**, **F1-Score** ve **ROC-AUC** metriklerinde **daha üstün** sonuçlar elde etmiştir.
- Özellikle **Recall** değerinin (%79.00'a karşı %75.60) daha yüksek olması, SVM'nin pozitif (hastalık) vakalarını Random Forest'a göre daha başarılı bir şekilde tespit ettiğini göstermektedir.
- Ensemble yöntemlerine benzer şekilde, SVM de **F1-Score** (ortalamanın dengeli bir ölçüsü) ve **ROC-AUC** (sınıflandırıcının ayırma yeteneği) değerlerinde RF'i geride bırakarak, bu iki model arasındaki en iyi genel performans gösteren model olmuştur.

Sınıf	Precision	Recall	F1-Score	ROC-AUC
NORM	0.8151	0.9107	0.8602	0.9435
MI	0.7579	0.7400	0.7489	0.9229
STTC	0.6632	0.8464	0.7437	0.9289
CD	0.7455	0.7500	0.7477	0.9083
HYP	0.5714	0.7023	0.6301	0.9049

Tablo 8. SVM Top 200 CW modelinin sınıflara göre metrikleri

- **Normal EKG (NORM)** sınıfı, beklenen şekilde tüm metriklerde en yüksek skorları (`F1: 0.8602`, `ROC-AUC: 0.9435`) almıştır; bu durum veri setindeki dengesizliğin ve bu sınıfın doğasından gelen öğrenme kolaylığını yansıtmaktadır.
- **Hipertrofi (HYP)**, tüm sınıflar arasında en düşük **F1-Score** (`0.6301`) ve **Precision** (`0.5714`) değerlerine sahiptir. Bu, aynı zamanda veri setindeki en

azınlık sınıf olmasıyla tutarlıdır ve modelin bu nadir vakaları doğru pozitif olarak etiketlemede zorlandığını göstermektedir.

- **Miyokard Enfarktüsü (MI) ve İletim Bozukluğu (CD)** sınıfları, Precision ve Recall değerlerinde dengeli bir başarı göstererek F1-Score'larını '~0.748' seviyesinde tutmuştur.
- **ST/T Değişikliği (STTC)** sınıfında 'Recall (0.8464)' oldukça yüksek iken, 'Precision (0.6632)' düşüktür; bu da modelin bu sınıfı iyi yakaladığını, ancak bunu yaparken daha fazla "Normal" vakayı yanlışlıkla STTC olarak etiketlemiş olabileceğini (yanlış pozitif) düşündürmektedir.

5. TARTIŞMA VE SONUÇ

Bu çalışmada PTB-XL+ veri seti kullanılarak 5 üst sınıf (NORM, MI, STTC, CD, HYP) için Random Forest tabanlı bir sınıflandırma hattı kurulmuştur. Ön işleme aşamasında eksik verilerin rastgele dağılmadığı gözlemlenmiş; özellikle P-dalgası ile ilişkili özniteliklerdeki eksikliğin MI ve STTC sınıflarında daha yüksek olması nedeniyle, eksik değerler "silinmek" yerine **eksiklik bayrağı (is_missing_*)** ile birlikte modele taşınmıştır. Bu tercih, eksikliğin potansiyel klinik anlamını koruyarak modelin "ölçülemeyen/okunamayan" durumları da öğrenebilmesini sağlamıştır.

Sonuçlar, öznitelik sayısının artırılmasının genel performansı iyileştirdiğini göstermektedir. Top-50'den Top-200'e geçildiğinde Accuracy ve F1 skorlarında artış görülmüş, ROC-AUC değerleri de 0.90+ seviyesinde seyretmiştir (Tablo 4). Bu, PTB-XL+'ın 12SL tabanlı sayısal özniteliklerinin sınıfları ayırma gücünün yüksek olduğunu göstermektedir. Ensemble undersampling yaklaşımı ise recall'ı artırsa da, precision ve accuracy'de düşüşe yol açtığı için toplam F1'de sınırlı kazanç üretmiştir. Bu sonuç pratikte şu anlama gelir: undersampling daha çok "kaçırmama" tarafını güçlendirirken, class weight yaklaşımı daha dengeli bir model davranışı üretmektedir diye yorumlanabilir.

Sınıf bazlı değerlere bakıldığında NORM sınıfında yüksek recall elde edilmiş, MI ve STTC sınıflarında ise F1 değerleri birbirine yakın ve dengeli gerçekleşmiştir (Tablo 5). Buna karşılık HYP sınıfı en zor sınıf olarak öne çıkmaktadır. HYP'nin hem precision hem F1 değerinin daha düşük kalması, hipertrofi örüntülerinin bazı kayıtlarda STTC veya iletim bozukluklarıyla örtüşebilmesine ve sınıf örnek sayısının daha sınırlı olmasına bağlanabilir. ROC eğrilerinde de benzer bir eğilim vardır:

NORM/MI/STTC sınıfları daha yüksek AUC verirken HYP diğer sınıflara göre daha düşüktür (Figür 7). Buna rağmen tüm sınıflarda AUC'nin 0.88+ olması modelin genel ayırtırma kapasitesinin güçlü olduğunu desteklemektedir; ancak "eşik sonrası karar" aşamasında özellikle HYP gibi sınıflarda hata oranı yükselmektedir.

Literatürle karşılaştırıldığında, bu çalışmanın yaklaşımı klasik makine öğrenmesi hattı açısından önceki çalışmalarla uyumludur: ölçek duyarsız ağaç tabanlı modellerin tercih edilmesi, sınıf dengesizliğine karşı class weight/undersampling denenmesi ve öznitelik seçiminin önem skorları üzerinden yapılması literatürde yaygındır. Buna karşın literatürde bazı çalışmaların yalnızca ikili senaryolara (örn. NORM vs MI) veya daha dar tanı kapsamına odaklandığı, bu sayede daha yüksek doğruluk değerleri raporlayabildiği görülmektedir. Bu çalışma ise 5 üst sınıfı aynı çerçevede ele aldığı için problem doğal olarak daha zordur; dolayısıyla metriklerin sınıf dengesizliği ve sınıflar arası örtüşme nedeniyle daha muhafazakâr seviyelerde kalması beklenen bir durumdur. Ayrıca bazı çalışmaların dış doğrulama (başka veri setinde test) veya daha yoğun model seçimi (XGBoost gibi) kullandığı düşünüldüğünde, burada Random Forest ile elde edilen 0.91 civarı ROC-AUC değerleri anlamlı bir taban başarı göstermektedir.

Ayrıca bu çalışma EKG kayıtlarından çıkarılan öznitelikler arasında T dalgalarının diğer dalgalara göre baskın olarak daha önemli olduğunu göstermektedir. Hedef tanı sınıflamasında sadece T dalgası üzerinden bir sınıflandırıcı model yapmak gelecek hedeflerden birisidir. Böyle bir sistem daha ya da basit cihazlar aracılığıyla hızlı bir şekilde tanı yapılmasını sağlayabilir.

Bu çalışmanın başlıca sınırlılığı, sınıf dengesizliğinin yalnızca sınıf ağırlıkları ve basit undersampling ile ele alınması ve model kalibrasyonu/olasılık güvenilirliği üzerine ek analiz yapılmamış olmasıdır. Ayrıca öznitelik önem skorları ağaç tabanlı yöntemlerde belirli yanlışlıklara açık olabildiğinden, seçilen Top-N kümelerin stabilitesi farklı tohumlarla ayrıca kontrol edilebilir.

Bu çalışmanın devamı olarak klinik kullanıma entegrasyon için bir kullanıcı arayüzü hazırlanması hedeftir. Böylece klinikte Kardiyak tanılar için bir uygulama hazır hale gelecektir.

Gelecekteki çalışmalar için üç somut öneri öne çıkmaktadır: (i) RandomForest yerine veya yanında XGBoost/LightGBM gibi gradient boosting yöntemlerinin denenmesi ve azınlık sınıflar için hedef odaklı ağırlıklandırma yapılması, (ii) BalancedRandomForest / EasyEnsemble gibi dengesizlikle daha uyumlu topluluk yöntemlerinin kullanılması, (iii) sınıf bazlı eşiklerin belirlenmesinde olasılık kalibrasyonu (sigmoid/isotonic) ve hedefe yönelik kısıtlar (ör. minimum HYP recall) ile daha kontrollü bir karar mekanizması kurulması. Ek olarak, HYP performansını artırmak için alt sınıf düzeyinde (ör. LVH/RVH) daha homojen etiketleme veya klinik olarak ilişkili ek öznitelikler (ör. vektörkardiyografik ölçümler) değerlendirilebilir.

6. KAYNAKLAR

- [1] Taconné, M., Corino, V. D., & Mainardi, L. (2024). An ECG-Based Model for Left Ventricular Hypertrophy Detection: A Machine Learning Approach. *IEEE Open Journal of Engineering in Medicine and Biology*.
- [2] Österlund, R., & Rekstad, H. (2025). Machine learning models for classification of myocardial infarction using the PTB-XL dataset.
- [3] Raipal, H., Sas, M., Lockwood, C., Joakim, R., Peters, N. S., & Falkenberg, M. (2020, September). Interpretable xgboost based classification of 12-lead ecgs applying information theory measures from neuroscience. In 2020 Computing in Cardiology (pp. 1-4). IEEE.
- [4] Wagner, P., Strodthoff, N., Bousseljot, R. D., Kreiseler, D., Lunze, F. I., Samek, W., & Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. *Scientific data*, 7(1), 1-15.
- [5] Strodthoff, N., Mehari, T., Nagel, C., Aston, P. J., Sundar, A., Graff, C., ... & Schaeffter, T. (2023). PTB-XL+, a comprehensive electrocardiographic feature dataset. *Scientific data*, 10(1), 279.
- [6] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581-592.

- [7] Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling* (Vol. 26, p. 13). New York: Springer.
- [8] Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical transactions of the royal society A: Mathematical, Physical and Engineering Sciences*, 374(2065), 20150202.
- [9] Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of machine learning research*, 3(Mar), 1157-1182.
- [10] Breiman, L. (2001). Random forests. *Machine learning*, 45(1), 5-32.
- [11] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9), 1263-1284.
- [12] Liu, X. Y., Wu, J., & Zhou, Z. H. (2008). Exploratory undersampling for class-imbalance learning. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 39(2), 539-550.

7. UYGULAMA

<https://github.com/AykutN/PTB-XL-Heart-Anomaly-Diagnosis-Project>

<https://physionet.org/content/ptb-xl-plus/1.0.1/> [veri seti, PTB-XL+]

<https://physionet.org/content/ptb-xl/1.0.3/> [ver seti, PTB-XL]