

Kalp Anomalilerinin Denetimli Öğrenme ile Sınıflandırılması

İstanbul Üniversitesi, Fen Fakültesi, Bilgisayar Bilimleri Bölümü

M. Yusuf Aykut

İbrahim Abushawish

Samet Ertuğrul Kurum

Samet Baturay

Aralık 2025



Giriş

Literatür Taraması

Yöntem

- Veri Seti Tanımı

- Keşifsel Analiz: PCA ve Aykırı Değerler

- Ön İşleme

- Öznitelik Seçimi

- Model Seçimi ve Eğitim

Sonuçlar

Tartışma ve Gelecek Çalışmalar

Referanslar

- ▶ Elektrokardiyografi (EKG), kalp hastalıklarının erken ve doğru tanısında kritik öneme sahip, kalbin elektriksel aktivitesini kaydeden bir yöntemdir.
- ▶ EKG sinyalinin morfolojisi ve dalga formlarının süre/genlik özellikleri; miyokard, ritim ve iletim patolojilerinin tespitinde kullanılır.
- ▶ Yapay zeka ve makine öğrenmesi uygulamalarının klinik pratikte doktorlara yardımcı karar destek sistemleri olarak yaygınlaşması beklenmektedir.

- ▶ PTB-XL+ veri setinden çıkarılmış EKG özniteliklerini kullanarak:
 - ▶ Normal ve 4 farklı anomali üst sınıfını (NORM, MI, STTC, CD, HYP) sınıflandırmak,
 - ▶ Veri dengesizliği sorununa yönelik yöntemleri incelemek ve karşılaştırmak,
- ▶ Denetimli öğrenme temelli, açıklanabilir bir sınıflandırma hattı tasarlamak ve değerlendirmek.

PTB-XL ve Georgia ECG veri setlerinde, sol ventriküler hipertrofi (LVH) tespiti [1]:

- ▶ Yalnızca NORMAL ve LVH etiketli kayıtlar kullanılmış, düşük kaliteli sinyaller elenmiştir.
- ▶ Özellik çıkarımı araştırmacılar tarafından yapılmış; Logistic Regresyon, Rastgele Orman (RF) ve Destek Vektör Makinesi (SVM) denenmiştir.
- ▶ RF ve SVM ile %87 üzerinde duyarlılık ve özgüllük elde edilmiştir.
- ▶ Veri dengesizliği: normal sınıfta downsampling, 100 kez tekrarlı eğitim ve ensemble ile telafi edilmiştir.
- ▶ SFFS ile en önemli 5 özellik seçilmiş, basitleştirilmiş modeller kurulmuştur.

Miyokardiyal Enfarktüs tespiti için klasik ML ve CNN karşılaştırması [2]:

- ▶ 7 klasik model: KNN, SVM, RF, XGBoost, Decision Tree, Gaussian Naive Bayes vb.
- ▶ Eksik verilerde `SimpleImputer`, ağaç dışı modellerde `StandardScaler` kullanılmıştır.
- ▶ PTB-XL'den yalnızca NORM ve MI etiketli, 100 Hz, 12 derivasyonlu EKG'ler alınmıştır.
- ▶ Veri MI referanslı 70/15/15 (train/val/test) bölünmüş, yalnızca eğitim seti dengelenmiştir.
- ▶ En yüksek doğruluk: XGBoost ile %89; ardından SVM ve RF %88 düzeyinde.

PhysioNet/CinC 2020 Challenge, 12 derivasyonlu EKG ve XGBoost [3]:

- ▶ Çoklu etiket problemi için her etiket için ayrı bir ikili XGBoost modeli eğitilmiştir.
- ▶ Sınıf dengesizliği: undersampling + K-fold çapraz doğrulama ile ele alınmıştır.
- ▶ Çıktı olasılıkları için sınıf bazlı, yüksek eşik değerleri (ör. 0.9) kullanılmıştır.
- ▶ Challenge skoru 0.155 olup, katılan takımlar arasında orta sıralarda yer almıştır.

- ▶ PTB-XL+: 12 derivasyonlu EKG dalga formlarından üç analiz aracının (GE Marquette 12SL, Uni-G, ECGDeli) çıkardığı öznitelikleri içerir.
- ▶ Süreler, genlikler, segment başlangıç/bitişleri, alanlar ve vektörkardiyografik ölçümler gibi klinik olarak yorumlanabilir özellikler sunar.
- ▶ 12SL'nin otomatik tanı ifadeleri ve PTB-XL etiketlerinin SNOMED CT eşlemeleri mevcuttur.
- ▶ Bu sayede, modeller klinisyen etiketleri ile otomatik ifadeler arasında karşılaştırmalı olarak eğitilip değerlendirilebilir [5].


PTB-XL Demografik ve Tanısal Özellikler

- ▶ 18.869 hastadan, 10 saniyelik 21.799 klinik 12 derivasyonlu EKG kaydı (500 ve 100 Hz sürümleri mevcut).
- ▶ Yaş dağılımı 40–80 yaşta yoğun, ortalama 62.8 yıl; ortalama boy 166.7 cm, kilo 71.0 kg.
- ▶ Cinsiyet: %52.1 erkek, %47.9 kadın.
- ▶ Veri çerçevesi: 21.388 kayıt, 793 sütun (750 sayısal, 42 tamsayı, 1 kategorik).

Sınıf Dağılımları ve Dengesizlik

- ▶ Beş üst sınıf: Normal, MI, ST/T Değişikliği (STTC), İletim Bozukluğu (CD), Hipertrofi (HYP).
- ▶ Örnek dağılımı yaklaşık olarak:
 - ▶ NORM: %44.5
 - ▶ MI: %25.4
 - ▶ STTC: %13.2
 - ▶ CD: %10.9
 - ▶ HYP: %6.1
- ▶ Belirgin sınıf dengesizliği mevcuttur: normal kayıtlar veri setinin neredeyse yarısını oluştururken, HYP oldukça azdır.
- ▶ Bu durum, modellerin azınlık sınıfları öğrenmesini zorlaştırabilir ve metriklerin yanıltıcı şişmesine yol açabilir.

Figür: PCA Düzleminde Veri Dağılımı ve Aykırı Değerler



PCA Grafiğinin Yorumu (2B Özet)

- ▶ PCA, yüksek boyutlu EKG özniteliklerini iki ana bileşen üzerinde özetleyerek dağılımı görselleştirir [9].
- ▶ Grafikte **PC1** yaklaşık ~ 0.21 , **PC2** yaklaşık ~ 0.13 varyansı açıklamaktadır; ilk iki bileşen toplamda ~ 0.34 varyansı yakalar.
- ▶ Sınıflar (NORM, MI, STTC, CD, HYP) 2B projeksiyonda belirgin biçimde **üst üste biner**:
 - ▶ Bu durum, ayrımın tek/az sayıda lineer ekseninde değil; **çok boyutlu ve nonlinear** örüntülerde oluştuğunu düşündürür.
- ▶ **Aykırı örnekler** (x ile işaretli) çoğunlukla bulutun dış bölgelerinde konumlanır:
 - ▶ Ölçekleme/istatistiksel özetleri etkileyerek modele gürültü taşıyabilir,
 - ▶ Ancak klinik açıdan **nadir ama gerçek** patoloji örnekleri olabileceği için doğrudan silinmemiş; sonraki adımlarda (varyans filtreleme, RF) sağlam (robust) öğrenme ile ele alınmıştır.

- ▶ Klinik üst bilgi tablosu ile 12-lead öznitelik tablosu `ecg_id` üzerinden birleştirilmiştir.
- ▶ SCP-ECG tanı kodları 5 ana üst sınıfa (NORM, MI, STTC, CD, HYP) dönüştürülmüştür.
- ▶ Herhangi bir tanı sınıfına girmeyen veya etiketi olmayan 411 kayıt çıkarılmış, 21.388 kayıt kalmıştır.
- ▶ Veri sızıntısını önlemek için tüm dönüşümler eğitim/val/test ayırımından *sonra* ve eğitim seti üzerinde fit edilmiştir [12].

Aykırı Değer Tespiti: Isolation Forest


Çalışmada kullanılan aykırı değer tespit yöntemi: **Isolation Forest (iForest)**:

- ▶ **Tablo 3'**te her tanı sınıfı için iForest ile aykırı değer analizi yapılmıştır.
- ▶ Her sınıf için yaklaşık **%3.3–%7.2** oranında aykırı değer tespit edilmiştir.
- ▶ **Temel fikir:** iForest, rastgele ağaçlar ile örneklerin *izolasyon zorluğunu* ölçer ve her örnek için bir **anomali skoru** üretir.
- ▶ **Yorum:** Normal noktalar genellikle daha fazla bölünme ile izole edilirken, **daha kolay izole edilen** (daha kısa yol uzunluğuna sahip) örnekler aykırı değer olarak işaretlenir.
- ▶ **Eşikleme:** `contamination="auto"` ile yöntem, veri dağılımına göre **otomatik** bir eşik (threshold) belirler.
- ▶ iForest, **yüksek boyutlu** veri setlerinde etkinliği gösterilmiş, ölçeklenebilir bir aykırı değer tespit yaklaşımıdır.

Eksik Veriler: Demografi ve EKG


- ▶ Demografik değişkenler:
 - ▶ Boy: %67.65 eksik, kilo: %56.21 eksik; bu nedenle modelden tamamen çıkarılmıştır.
- ▶ EKG öznitelikleri:
 - ▶ T_AxisFront_Global ve R_AxisFrontal_Global: çok az sayıda eksik; ilgili kayıtlar silinmiştir.
 - ▶ P dalgası ile ilişkili P_On_Global, P_Off_Global, P_Dur_Global, P_AxisFront_Global, PR_Int_Global, HR_Atrial_Global: yaklaşık %8 eksik.
- ▶ Satır bazlı eksiklik oranı %1'in altında olduğundan, satır silme yalnızca etiketi eksik örneklerle sınırlı tutulmuştur.

Figür 1: Eksik Değer Analizi



Figür 2: Eksik Değer Analizi

Eksik Veri İçeren Kayıtların Tanı Sınıflarına Göre Dağılımı




- ▶ P dalgası ile ilişkili özniteliklerdeki eksiklik, MI ve STTC sınıflarında anlamlı biçimde daha sık görülmektedir [11].
- ▶ Bu nedenle eksiklik, yalnızca teknik bir sorun değil, fizyolojik bir işaret (ör. atriyal fibrilasyon) olarak ele alınmıştır.
- ▶ Strateji:
 - ▶ P dalgası öznitelikleri için: sabit değer (0.0) + `is_missing` bayrağı ile kodlama.
 - ▶ Diğer sayısal öznitelikler için: eğitim seti medyanı + `is_missing` bayrağı.
 - ▶ `heart_axis`: %38 eksiklik ve düşük ek bilgi nedeniyle tamamen çıkarılmıştır.

Veri Bölme, İmputasyon ve Ölçekleme

- ▶ Veri, `strat_fold` etiketine göre üç kümeye ayrılmıştır:
 - ▶ Eğitim: 17.084 örnek (%79.9)
 - ▶ Doğrulama: 2.146 örnek (%10.0)
 - ▶ Test: 2.158 örnek (%10.1)
- ▶ Eksik değer doldurma (imputasyon):
 - ▶ Sadece eğitim seti üzerinde `SimpleImputer(strategy="median")` fit edilmiştir.
 - ▶ Aynı imputer, doğrulama ve test kümelerine uygulanmıştır.
- ▶ Ölçekleme:
 - ▶ Sayısal sütunlar için `StandardScaler` yalnızca eğitim setinde fit edilmiştir.
 - ▶ Eksiklik bayrakları ölçekleme dışında tutulmuştur.

Figür 3: Splitlere Göre Sınıf Dağılımı



Sınıf Dengesizliği


- ▶ Eğitim/val/test kümeleri oluşturulduktan sonra sınıf dağılımları incelenmiş, dengesizliğin korunduğu görülmüştür.
- ▶ Dengesizliğin model üzerindeki etkisini azaltmak için iki ana yaklaşım kullanılmıştır:
 - ▶ Sınıf ağırlıkları (`class_weight="balanced"`)
 - ▶ Rastgele undersampling (yalnızca eğitim kümesinde)
- ▶ Sınıf ağırlıkları, yalnızca eğitim verisi üzerinden hesaplanmış ve azınlık sınıfların kayıp fonksiyonuna katkısı artırılmıştır.

- ▶ oversampling yöntemleri (SMOTE, ADASYN vb.) denenmiş ancak başarılı sonuçlar elde edilmemiştir.
 - ▶ Çoklu sınıf yapısı ve yüksek boyutlu öznitelik uzayı nedeniyle sentetik örnekler gerçekçi değildir.
 - ▶ veri sayısını değiştirmedeğitilen modeller oversampling ile aynı aynı sayılabilecek performans göstermiştir.

Öznitelik Seçimi: Varyans Eşikleme

- ▶ İlk adım: *Variance Threshold* yöntemi ile varyansı çok düşük, sabite yakın öznitelikler elenmiştir.
- ▶ Varyansları 0.05'in altında olan öznitelikler çıkarılmış; 793 özelliğin 186 tanesi bu nedenle elenmiştir.
- ▶ Böylece bilgi katkısı sınırlı, durağan ve gürültülü özellikler modelleme dışına alınmıştır.



Figür 3: Varyans Dağılımı



Öznitelik Seçimi: Random Forest Önem Skorları

- ▶ İkinci adım: `RandomForestClassifier` ile öznitelik önem sıralaması yapılmıştır.
- ▶ Model ayarları: `n_estimators=250`, `max_depth=12`, `random_state=42`, `n_jobs=-1`.
- ▶ Her ağaçta kullanılan bölünmelerdeki bilgi kazançları toplanarak normalize edilmiş önem skorları elde edilmiştir [7].
- ▶ En yüksek skoru alan 50, 100 ve 200 öznitelik; üç ayrı alt küme (Top-50, Top-100, Top-200) olarak tanımlanmıştır.
- ▶ Bu alt kümelerle ayrı RF modelleri eğitilerek özellik sayısının performansa ve overfitting'e etkisi incelenmiştir.


Figür 4: Öznitelik Seçimi ve Önem Düzeyleri



Şekil: Top-100 Öznitelik Korelasyon Isı Haritası filtreleme öncesi (varyanslı)

Şekil: RF Model Bazlı Önem Düzeyleri

Figür 5: Korelasyon Isı Haritası (Top-100) filtreleme sonrası



Şekil: Top-100 Öznitelik Korelasyon Isı Haritası filtreleme sonrası

Model Seçimi: Random Forest

- ▶ Bu çalışmada sınıflandırıcı olarak yalnızca Random Forest (RF) kullanılmıştır [7].
- ▶ Tercih nedenleri:
 - ▶ Nonlineer ilişkileri yakalayabilmesi,
 - ▶ Yüksek boyutlu öznitelik uzaylarında güçlü performans,
 - ▶ Ölçeklemeye görece duyarsız oluşu,
 - ▶ Öznitelik önem skorları ile yorumlanabilirlik sunması.
- ▶ Temel hiperparametreler tüm deneylerde sabitlenmiştir:
 - ▶ `n_estimators=250, max_depth=12, random_state=42, n_jobs=-1`.

Random Forest: Çalışma Prensipleri ve Mantığı

- ▶ **Temel fikir:** Tek bir karar ağacı yerine, *çok sayıda* farklı karar ağacını bir araya getirerek (ensemble) daha kararlı ve genellenebilir bir model elde etmek.
- ▶ **Bagging (Bootstrap Aggregation):** Her ağaç, eğitim verisinden *tekrar seçmeli* (bootstrap) örnekleme ile oluşturulan farklı bir alt veri kümesiyle eğitilir.
 - ▶ Böylece ağaçlar aynı veriyi görse bile farklı örüntüler öğrenir.
 - ▶ Amaç, tek ağaçların **yüksek varyansını** azaltmaktır.
- ▶ **Rastgele öznitelik altkümesi:** Her düğümde bölme yapılırken tüm öznitelikler yerine rastgele seçilmiş bir alt küme değerlendirilir.
 - ▶ Ağaçlar arası korelasyonu düşürür, çeşitliliği artırır.
 - ▶ Benzer güçlü özniteliklerin tüm ağaçları domine etmesini engeller.
- ▶ **Birleştirme (Aggregation):** Sınıflandırmada ağaç çıktıları çoğunluk oyu / olasılık ortalaması ile birleştirilir [7]:

$$\hat{p}(y = c | x) = \frac{1}{T} \sum_{t=1}^T p_t(y = c | x), \quad \hat{y} = \arg \max_c \hat{p}(y = c | x)$$

- ▶ **Yan ürünler:** *Out-of-bag* (OOB) örnekleriyle hızlı hata tahmini ve öznitelik önem skorları (feature importance) elde edilebilir.

Dengesizlik Deney Tasarımı

- ▶ Aynı RF modeli altında iki değişkenin etkisi incelenmiştir:
 - ▶ Öznitelik sayısı: Top-50 / Top-100 / Top-200
 - ▶ Dengesizlik stratejisi: sınıf ağırlıkları vs. undersampling
- ▶ Senaryolar:
 - ▶ **CW-50 / CW-100 / CW-200**: `class_weight="balanced"` yaklaşımı [13] ile üç farklı öznitelik seti.
 - ▶ **US-200**: Sadece eğitim setinde rastgele undersampling [14] + Top-200 öznitelik.
- ▶ Olasılıksal çıktılar için sınıf bazlı eşikler, F1 skorunu maksimize edecek şekilde 0.01 aralıklarla taranmıştır.

Model Değerlendirme Metrikleri (Tanımlar)

- Her sınıf için one-vs-rest ikili senaryo kurulur: ilgili sınıf *pozitif*, diğerleri *negatif*.
- Karışıklık matrisi terimleri:

TP: doğru pozitif, FP: yanlış pozitif, FN: yanlış negatif, TN: doğru negatif

- **Accuracy (Doğruluk)** — genel doğru sınıflandırma oranı (dengesiz veri varsa yanıltıcı olabilir):

$$\text{Acc} = \frac{TP + TN}{TP + FP + FN + TN}$$

- **Precision (Kesinlik)** — “pozitif” dediğim örneklerin ne kadarı gerçekten pozitif? (yanlış alarm maliyeti yüksekse önemlidir):

$$\text{Prec} = \frac{TP}{TP + FP}$$

- **Recall / Sensitivity (Duyarlılık)** — gerçek pozitiflerin ne kadarını yakaladım? (kaçırma maliyeti yüksekse önemlidir):

$$\text{Rec} = \frac{TP}{TP + FN}$$

ROC-AUC, Eşik ve Çok Sınıflı Özetleme

- **F1 skoru** — Precision ve Recall arasında denge (dengesiz sınıflarda sıklıkla tercih edilir):

$$F1 = \frac{2 \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}}$$

- **ROC eğrisi**: eşik τ değiştikçe TPR ve FPR değerlerinin izlediği eğri:

$$\text{TPR}(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)} \quad , \quad \text{FPR}(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)}$$


- **AUC**: ROC eğrisinin altında kalan alan; eşikten bağımsız ayrıştırma gücü:

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}) d(\text{FPR})$$

- Bu çalışmada metrikler doğrulama setinde hesaplanmış; sınıf bazlı eşikler τ_c F1'i maksimize edecek şekilde taranmış ve en iyi kurulum test setinde raporlanmıştır.

- ▶ Tüm analiz ve deneyler Python 3 ortamında, açık kaynak kütüphaneler kullanılarak gerçekleştirilmiştir.
- ▶ Bağımlılıklar `requirements.txt` ile yönetilmiştir: `pandas`, `numpy`, `scikit-learn`, `matplotlib`, `seaborn`.
- ▶ Deney akışı modülerleştirilmiştir: ön işleme hattı (`preprocessing/pipeline.py`), model eğitimi ve metrik/çizimler (`training/train_models.py`), makale figürleri (`figures/generate_figures.py`).
- ▶ Kod ve deney çıktıları sürüm kontrolü ile yönetilmiş ve herkese açık repo olarak paylaşılmıştır: github.com/AykutN/PTB-XL-Heart-Anomaly-Diagnosis-Project

Sınıf Ağırlıkları vs. Undersampling



Not: Solda eğitim seti sınıf dağılımı, sağda `class_weight="balanced"` ile hesaplanan ağırlıklar gösterilmektedir.

Kısa yorum

- **Class-weight:** Örnek sayısını değiştirmez; azınlık sınıfların hatasını daha fazla cezalandırarak öğrenmeyi dengeler.
- **Undersampling:** Çoğunluk sınıfından örnek *atar*; veri boyutunu düşürür ve bilgi kaybı riski taşır.

- **Sol grafik (dağılım):** Eğitim seti dengesizdir; **NORM** en büyük, **HYP** en küçük sınıftır.
- **Sağ grafik (ağırlıklar):** balanced yaklaşımı sınıf sıklığının tersiyle orantılı ağırlık verir:

$$w_c \propto \frac{1}{n_c}$$

- Bu nedenle **NORM** için $w < 1$, **HYP** için $w > 1$ beklenir (kırmızı çizgi 1.0 referansıdır).

Genel Performans (Eğitim / Val) — Random Forest

Kurulum	Accuracy	Precision	Recall	F1	ROC-AUC
RF + Top-50	0.5533	0.6764	0.7653	0.7153	0.904
RF + Top-100	0.5843	0.7129	0.7368	0.7239	0.909
RF + Top-200	0.5885	0.7130	0.7560	0.7321	0.915
RF + Top-200 + Ensemble	0.5449	0.6841	0.7859	0.7228	0.915

Not: Ensemble kurulumunda yalnızca Recall yaklaşık %78.6 olarak raporlanmıştır; diğer metrikler burada verilmemiştir.

SVM Sonuçları (Top-200, Class-Weight)

Sınıf	Precision	Recall	F1-Score	ROC-AUC
NORM	0.8151	0.9107	0.8602	0.9435
MI	0.7579	0.7400	0.7489	0.9229
STTC	0.6632	0.8464	0.7437	0.9289
CD	0.7455	0.7500	0.7477	0.9083
HYP	0.5714	0.7023	0.6301	0.9049

Tablo 8. SVM Top-200 CW modelinin sınıflara göre metrikleri

SVM (Top-200, CW) — Kısa Yorum

- ▶ **NORM** sınıfı tüm metriklerde en yüksek skora sahiptir ($F1 = 0.8602$, $ROC-AUC = 0.9435$); bu durum sınıf dengesizliği ve NORM'un görece kolay ayrışması ile uyumludur.
- ▶ **HYP** sınıfı en düşük $F1$ (0.6301) ve **Precision** (0.5714) değerlerini üretmiştir; azınlık sınıf olması nedeniyle modelin doğru pozitif üretmekte zorlandığını göstermektedir.
- ▶ **MI** ve **CD** sınıfları Precision/Recall açısından daha dengeli olup $F1 \approx 0.748$ bandındadır.
- ▶ **STTC** için **Recall** (0.8464) yüksek, **Precision** (0.6632) düşüktür; model STTC'yi iyi yakalarken daha fazla yanlış pozitif üretiyor olabilir.


- ▶ Top-50'den Top-200'e geçiş, Accuracy ve F1 metriklerinde artış sağlamıştır.
- ▶ ROC-AUC tüm senaryolarda 0.90 üzerinde, Top-200 ile 0.915 seviyesine ulaşmaktadır.
- ▶ Bu sonuç, PTB-XL+'ın sayısal EKG özniteliklerinin sınıfları ayırma gücünün yüksek olduğunu göstermektedir.

Sınıf Bazlı Sonuçlar (CW-200)

- ▶ NORM: Eşik 0.30; Precision %79.27, Recall %92.11, F1 %85.21.
- ▶ MI: Eşik 0.45; Precision %74.91, Recall %72.73, F1 %73.80.
- ▶ STTC: Eşik 0.46; Precision %69.24, Recall %79.08, F1 %73.84.
- ▶ CD: Eşik 0.45; Precision %76.87, Recall %70.36, F1 %73.47.
- ▶ HYP: Eşik 0.43; Precision %56.23, Recall %63.74, F1 daha düşük seviyededir.

- ▶ ROC eğrileri tüm sınıflar için yüksek ayrıştırma gücü göstermektedir:
 - ▶ NORM: AUC 0.938
 - ▶ MI: AUC 0.923
 - ▶ STTC: AUC 0.929
 - ▶ CD: AUC 0.901
 - ▶ HYP: AUC 0.883
- ▶ HYP diğer sınıflara göre daha zor bir sınıftır; buna rağmen AUC'nin 0.88 üzerinde olması genel ayrıştırma kapasitesinin güçlü olduğunu göstermektedir.

Figür 5: ROC Eğrileri (Random Forest - Top-200)



- ▶ PTB-XL+ veri seti üzerinde 5 üst sınıf (NORM, MI, STTC, CD, HYP) için RF tabanlı bir sınıflandırma hattı kurulmuştur.
- ▶ Eksik verilerin rastgele dağılmadığı, özellikle P dalgası ile ilgili özniteliklerde MI ve STTC'de yoğunlaştığı görülmüş; bu nedenle eksiklik, *bilgi taşıyan* bir durum olarak modele dahil edilmiştir.
- ▶ Öznitelik sayısının artması genel olarak performansı iyileştirmiş; ROC-AUC değerleri 0.90+ bandında seyretmiştir.
- ▶ Undersampling, recall değerlerini artırsa da precision ve accuracy'de azalmaya yol açmış; sınıf ağırlıkları daha dengeli bir davranış sunmuştur.

Sınıf Bazlı Değerlendirme ve Sınırlılıklar

- ▶ NORM sınıfında yüksek recall elde edilirken, MI ve STTC sınıflarında dengeli F1 değerleri gözlenmiştir.
- ▶ HYP en zor sınıf olup, hem sınıf örnek sayısının azlığı hem de diğer anomali örüntüleriyle örtüşmesi nedeniyle daha düşük metrikler üretmektedir.
- ▶ Çalışmanın sınırlılıkları:
 - ▶ Sınıf dengesizliği yalnızca sınıf ağırlıkları ve basit undersampling ile ele alınmıştır.
 - ▶ Olasılık kalibrasyonu ve karar eşiklerinin klinik hedeflere göre optimize edilmesi detaylı incelenmemiştir.
 - ▶ RF önem skorları belirli yanlılıklara açık olabilir; Top-N kümelerin stabilitesi farklı tohumlarla ayrıca analiz edilebilir.

- ▶ RF yerine veya yanında XGBoost/LightGBM gibi gradient boosting yöntemlerinin denenmesi.
- ▶ Dengesizliğe duyarlı topluluk yöntemleri: Balanced Random Forest, EasyEnsemble vb.
- ▶ Sınıf bazlı eşiklerin, olasılık kalibrasyonu (sigmoid/isotonic) ve klinik kısıtlar (ör. minimum HYP recall) ile birlikte optimize edilmesi.
- ▶ HYP performansını artırmak için alt sınıf (ör. LVH/RVH) düzeyinde daha homojen etiketleme ve ek vektörkardiyografik özniteliklerin değerlendirilmesi.

Gelecek Çalışmalar (Devam)


LLM modellerinden yararlanılarak bu sonuçlar bulunmuştur:

- ▶ Ham EKG dalga formu üzerinden 1D-CNN/Transformer tabanlı derin öğrenme modelleri ve klasik özniteliklerle hibrit yaklaşımların karşılaştırılması.
- ▶ Özellikle azınlık sınıflar için özdenetimli (self-supervised) ön eğitim (ör. contrastive learning) ile temsil öğrenimi ve ardından ince ayar (fine-tuning).
- ▶ Değerlendirmede hasta-bazlı (patient-wise) bölme, harici veri seti ile genelleme testi ve cihaz/merkez farklılıklarına karşı alan uyarlama (domain adaptation).
- ▶ Gürültü/artefakt dayanıklılığı: veri artırma (noise, baseline wander), kalite kontrol (signal quality index) ve derivasyon (lead) seçiminin etkisinin analizi.
- ▶ Açıklanabilirlik ve klinik doğrulama: SHAP/permütasyon önemleri ile kararların yorumlanması ve hata analiziyle (confusion + örnek inceleme) model iyileştirme döngüsü.

Süreç Fotoğrafları




Toplantı 1



Toplantı 2

Gantt Şeması



Proje Gantt Şeması

Bu sunumda yer alan tüm analizler, yorumlar ve sonuçlar **yazarlar tarafından** gerçekleştirilmiş olup, herhangi bir dış kaynaktan izinsiz alıntı veya intihal içermemektedir.

Ayrıca, çalışma kapsamında **kod geliştirme süreçlerinde** ve **bazı metin bölümlerinin taslaklandırılması/düzenlenmesinde** Büyük Dil Modellerinden (LLM) destek alınmıştır.

- [1] M. Taconné, V. D. Corino, & L. Mainardi, *An ECG-Based Model for Left Ventricular Hypertrophy Detection: A Machine Learning Approach*, IEEE Open Journal of Engineering in Medicine and Biology (2024).
- [2] R. Österlund, & H. Rekstad, *Machine learning models for classification of myocardial infarction using the PTB-XL dataset* (2025).
- [3] H. Raipal, M. Sas, C. Lockwood, J. R., N. S. Peters, & M. Falkenberg, *Interpretable XGBoost based classification of 12-lead ECGs applying information theory measures from neuroscience*, In *2020 Computing in Cardiology* (IEEE, 2020).
- [4] P. Wagner, N. Strodthoff, R.-D. Bousseljot, D. Kreiseler, F. I. Lunze, W. Samek, T. Schaeffter, *PTB-XL, a large publicly available electrocardiography dataset*, Scientific Data, 7, 154 (2020).
<https://doi.org/10.1038/s41597-020-0495-6>
- [5] P. Wagner, T. Mehari, N. Strodthoff, et al., *PTB-XL+, a comprehensive electrocardiographic feature dataset*, Scientific Data (2023). <https://doi.org/10.1038/s41597-023-02153-8>
- [6] N. Strodthoff, P. Wagner, T. Schaeffter, W. Samek, *Deep learning for ECG analysis: Benchmarks and insights from PTB-XL*, arXiv preprint arXiv:2004.13701 (2020). <https://arxiv.org/abs/2004.13701>
- [7] L. Breiman, *Random forests*, Machine Learning, 45(1), 5–32 (2001).
<https://doi.org/10.1023/A:1010933404324>

- [8] I. Guyon, A. Elisseeff, *An introduction to variable and feature selection*, Journal of Machine Learning Research, 3, 1157–1182 (2003).
- [9] I. T. Jolliffe, J. Cadima, *Principal component analysis: A review and recent developments*, Philosophical Transactions of the Royal Society A, 374(2065), 20150202 (2016).
- [10] C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in random forest variable importance measures: Illustrations, sources and a solution*, BMC Bioinformatics, 8, 25 (2007).
<https://doi.org/10.1186/1471-2105-8-25>
- [11] D. B. Rubin, *Inference and missing data*, Biometrika, 63(3), 581–592 (1976).
<https://doi.org/10.1093/biomet/63.3.581>
- [12] M. Kuhn, & K. Johnson, *Applied Predictive Modeling*, Springer (2013).
- [13] H. He, & E. A. Garcia, *Learning from imbalanced data*, IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284 (2009).
- [14] X.-Y. Liu, J. Wu, & Z.-H. Zhou, *Exploratory undersampling for class-imbalance learning*, IEEE Transactions on Systems, Man, and Cybernetics, Part B, 39(2), 539–550 (2008).

- [15] J. A. C. Sterne, I. R. White, J. B. Carlin, M. Spratt, P. Royston, M. G. Kenward, J. R. Carpenter, *Multiple imputation for missing data in epidemiological and clinical research: Potential and pitfalls*, BMJ, 338, b2393 (2009). <https://doi.org/10.1136/bmj.b2393>
- [16] IBM, *Random forest*, IBM Think (erişim: 22 Aralık 2025). <https://www.ibm.com/think/topics/random-forest>
- [17] Corporate Finance Institute (CFI), *Bagging (Bootstrap Aggregation)*, (erişim: 22 Aralık 2025). <https://corporatefinanceinstitute.com/resources/data-science/bagging-bootstrap-aggregation/>

Sorularınız için teşekkür ederiz.

M. Yusuf Aykut İbrahim Abushawish Samet Ertuğrul Kurum Samet Baturay

