

Kalp Anomalilerinin Denetimli Öğrenme ile Sınıflandırılması

İstanbul Üniversitesi, Fen Fakültesi, Bilgisayar Bilimleri Bölümü

M. Yusuf Aykut

İbrahim Abu Shawish

Samet Ertuğrul Kurum

Samet Baturay

Aralık 2025



Giriş

Literatür Taraması

Yöntem

- Veri Seti Tanımı

- Ön İşleme

- Öznitelik Seçimi

- Model Seçimi ve Eğitim

Sonuçlar

Tartışma ve Gelecek Çalışmalar

Referanslar

- ▶ Elektrokardiyografi (EKG), kalp hastalıklarının erken ve doğru tanısında kritik öneme sahip, kalbin elektriksel aktivitesini kaydeden bir yöntemdir.
- ▶ EKG sinyalinin morfolojisi ve dalga formlarının süre/genlik özellikleri; miyokard, ritim ve iletim patolojilerinin tespitinde kullanılır.
- ▶ Yapay zeka ve makine öğrenmesi uygulamalarının klinik pratikte doktorlara yardımcı karar destek sistemleri olarak yaygınlaşması beklenmektedir.

- ▶ PTB-XL+ veri setinden çıkarılmış EKG özniteliklerini kullanarak:
 - ▶ Normal ve 4 farklı anomali üst sınıfını (NORM, MI, STTC, CD, HYP) sınıflandırmak,
 - ▶ Veri dengesizliği sorununa yönelik yöntemleri incelemek ve karşılaştırmak,
- ▶ Denetimli öğrenme temelli, açıklanabilir bir sınıflandırma hattı tasarlamak ve değerlendirmek.

- [1] PTB-XL ve Georgia ECG veri setlerinde, sol ventriküler hipertrofi (LVH) tespiti:
- ▶ Yalnızca NORMAL ve LVH etiketli kayıtlar kullanılmış, düşük kaliteli sinyaller elenmiştir.
 - ▶ Özellik çıkarımı araştırmacılar tarafından yapılmış; Logistic Regresyon, Rastgele Orman (RF) ve Destek Vektör Makinesi (SVM) denenmiştir.
 - ▶ RF ve SVM ile
 - ▶ Veri dengesizliği: normal sınıfta downsampling, 100 kez tekrarlı eğitim ve ensemble ile telafi edilmiştir.
 - ▶ SFFS ile en önemli 5 özellik seçilmiş, basitleştirilmiş modeller kurulmuştur.

[2] Miyokardiyal Enfarktüs tespiti için klasik ML ve CNN karşılaştırması:

- ▶ 7 klasik model: KNN, SVM, RF, XGBoost, Decision Tree, Gaussian Naive Bayes vb.
- ▶ Eksik verilerde `SimpleImputer`, ağaç dışı modellerde `StandardScaler` kullanılmıştır.
- ▶ PTB-XL'den yalnızca NORM ve MI etiketli, 100 Hz, 12 derivasyonlu EKG'ler alınmıştır.
- ▶ Veri MI referanslı 70/15/15 (train/val/test) bölünmüş, yalnızca eğitim seti dengelenmiştir.
- ▶ En yüksek doğruluk: XGBoost ile

[4] PhysioNet/CinC 2020 Challenge, 12 derivasyonlu EKG ve XGBoost:

- ▶ Çoklu etiket problemi için her etiket için ayrı bir ikili XGBoost modeli eğitilmiştir.
- ▶ Sınıf dengesizliği: undersampling + K-fold çapraz doğrulama ile ele alınmıştır.
- ▶ Çıktı olasılıkları için sınıf bazlı, yüksek eşik değerleri (ör. 0.9) kullanılmıştır.
- ▶ Challenge skoru 0.155 olup, katılan takımlar arasında orta sıralarda yer almıştır.

- ▶ PTB-XL+: 12 derivasyonlu EKG dalga formlarından üç analiz aracının (GE Marquette 12SL, Uni-G, ECGDeli) çıkardığı öznitelikleri içerir.
- ▶ Süreler, genlikler, segment başlangıç/bitişleri, alanlar ve vektörkardiyografik ölçümler gibi klinik olarak yorumlanabilir özellikler sunar.
- ▶ 12SL'nin otomatik tanı ifadeleri ve PTB-XL etiketlerinin SNOMED CT eşlemeleri mevcuttur.
- ▶ Bu sayede, modeller klinisyen etiketleri ile otomatik ifadeler arasında karşılaştırmalı olarak eğitilip değerlendirilebilir.

PTB-XL Demografik ve Tanısal Özellikler

- ▶ 18.869 hastadan, 10 saniyelik 21.799 klinik 12 derivasyonlu EKG kaydı (500 ve 100 Hz sürümleri mevcut).
- ▶ Yaş dağılımı 40–80 yaşta yoğun, ortalama 62.8 yıl; ortalama boy 166.7 cm, kilo 71.0 kg.
- ▶ Cinsiyet:
- ▶ Veri çerçevesi: 21.388 kayıt, 793 sütun (750 sayısal, 42 tamsayı, 1 kategorik).

Sınıf Dağılımları ve Dengesizlik


- ▶ Beş üst sınıf: Normal, MI, ST/T Değişikliği (STTC), İletim Bozukluğu (CD), Hipertrofi (HYP).
- ▶ Örnek dağılımı yaklaşık olarak:
 - ▶ NORM:
 - ▶ MI:
 - ▶ STTC:
 - ▶ CD:
 - ▶ HYP:
- ▶ Belirgin sınıf dengesizliği mevcuttur: normal kayıtlar veri setinin neredeyse yarısını oluştururken, HYP oldukça azdır.
- ▶ Bu durum, modellerin azınlık sınıfları öğrenmesini zorlaştırabilir ve metriklerin yanıltıcı şişmesine yol açabilir.

- ▶ Klinik üst bilgi tablosu ile 12-lead öznitelik tablosu `ecg_id` üzerinden birleştirilmiştir.
- ▶ SCP-ECG tanı kodları 5 ana üst sınıfa (NORM, MI, STTC, CD, HYP) dönüştürülmüştür.
- ▶ Herhangi bir tanı sınıfına girmeyen veya etiketi olmayan 411 kayıt çıkarılmış, 21.388 kayıt kalmıştır.
- ▶ Veri sızıntısını önlemek için tüm dönüşümler eğitim/val/test ayırımından *sonra* ve eğitim seti üzerinde fit edilmiştir.

Eksik Veriler: Demografi ve EKG


- ▶ Demografik değişkenler:
 - ▶ Boy:
- ▶ EKG öznitelikleri:
 - ▶ T_AxisFront_Global ve R_AxisFrontal_Global: çok az sayıda eksik; ilgili kayıtlar silinmiştir.
 - ▶ P dalgası ile ilişkili P_On_Global, P_Off_Global, P_Dur_Global, P_AxisFront_Global, PR_Int_Global, HR_Atrial_Global: yaklaşık
- ▶ Satır bazlı eksiklik oranı

Figür 1: Eksik Değer Analizi



Figür 2: Eksik Değer Analizi

Eksik Veri İçeren Kayıtların Tanı Sınıflarına Göre Dağılımı




- ▶ P dalgası ile ilişkili özniteliklerdeki eksiklik, MI ve STTC sınıflarında anlamlı biçimde daha sık görülmektedir.
- ▶ Bu nedenle eksiklik, yalnızca teknik bir sorun değil, fizyolojik bir işaret (ör. atriyal fibrilasyon) olarak ele alınmıştır.
- ▶ Strateji:
 - ▶ P dalgası öznitelikleri için: sabit değer (0.0) + `is_missing` bayrağı ile kodlama.
 - ▶ Diğer sayısal öznitelikler için: eğitim seti medyanı + `is_missing` bayrağı.
 - ▶ `heart_axis`:

Veri Bölme, İmputasyon ve Ölçekleme

- ▶ Veri, `strat_fold` etiketine göre üç kümeye ayrılmıştır:
 - ▶ Eğitim: 17.084 örnek (
 - ▶ Doğrulama: 2.146 örnek (
 - ▶ Test: 2.158 örnek (
- ▶ Eksik değer doldurma (imputasyon):
 - ▶ Sadece eğitim seti üzerinde `SimpleImputer(strategy="median")` fit edilmiştir.
 - ▶ Aynı imputer, doğrulama ve test kümelerine uygulanmıştır.
- ▶ Ölçekleme:
 - ▶ Sayısal sütunlar için `StandardScaler` yalnızca eğitim setinde fit edilmiştir.
 - ▶ Eksiklik bayrakları ölçekleme dışında tutulmuştur.

Figür 3: Splitlere Göre Sınıf Dağılımı



Sınıf Dengesizliği


- ▶ Eğitim/val/test kümeleri oluşturulduktan sonra sınıf dağılımları incelenmiş, dengesizliğin korunduğu görülmüştür.
- ▶ Dengesizliğin model üzerindeki etkisini azaltmak için iki ana yaklaşım kullanılmıştır:
 - ▶ Sınıf ağırlıkları (`class_weight="balanced"`)
 - ▶ Rastgele undersampling (yalnızca eğitim kümesinde)
- ▶ Sınıf ağırlıkları, yalnızca eğitim verisi üzerinden hesaplanmış ve azınlık sınıfların kayıp fonksiyonuna katkısı artırılmıştır.

- ▶ oversampling yöntemleri (SMOTE, ADASYN vb.) denenmiş ancak başarılı sonuçlar elde edilmemiştir.
 - ▶ Çoklu sınıf yapısı ve yüksek boyutlu öznitelik uzayı nedeniyle sentetik örnekler gerçekçi değildir.
 - ▶ veri sayısını değiştirmedeğitilen modeller oversampling ile aynı aynı sayılabilecek performans göstermiştir.

Öznitelik Seçimi: Varyans Eşikleme

- ▶ İlk adım: *Variance Threshold* yöntemi ile varyansı çok düşük, sabite yakın öznitelikler elenmiştir.
- ▶ Varyansları 0.05'in altında olan öznitelikler çıkarılmış; 793 özelliğin 186 tanesi bu nedenle elenmiştir.
- ▶ Böylece bilgi katkısı sınırlı, durağan ve gürültülü özellikler modelleme dışına alınmıştır.



Figür 3: Varyans Dağılımı



Öznitelik Seçimi: Random Forest Önem Skorları

- ▶ İkinci adım: `RandomForestClassifier` ile öznitelik önem sıralaması yapılmıştır.
- ▶ Model ayarları: `n_estimators=250`, `max_depth=12`, `random_state=42`, `n_jobs=-1`.
- ▶ Her ağaçta kullanılan bölünmelerdeki bilgi kazançları toplanarak normalize edilmiş önem skorları elde edilmiştir.
- ▶ En yüksek skoru alan 50, 100 ve 200 öznitelik; üç ayrı alt küme (Top-50, Top-100, Top-200) olarak tanımlanmıştır.
- ▶ Bu alt kümelerle ayrı RF modelleri eğitilerek özellik sayısının performansa ve overfitting'e etkisi incelenmiştir.

Figür 4: Öznitelik Seçimi ve Önem Düzeyleri



Şekil: Top-100 Öznitelik Korelasyon Isı Haritası filtreleme öncesi (varyanslı)

Şekil: RF Model Bazlı Önem Düzeyleri

Model Seçimi: Random Forest

- ▶ Bu çalışmada sınıflandırıcı olarak yalnızca Random Forest (RF) kullanılmıştır.
- ▶ Tercih nedenleri:
 - ▶ Nonlineer ilişkileri yakalayabilmesi,
 - ▶ Yüksek boyutlu öznitelik uzaylarında güçlü performans,
 - ▶ Ölçeklemeye görece duyarsız oluşu,
 - ▶ Öznitelik önem skorları ile yorumlanabilirlik sunması.
- ▶ Temel hiperparametreler tüm deneylerde sabitlenmiştir:
 - ▶ `n_estimators=250`, `max_depth=12`, `random_state=42`, `n_jobs=-1`.

Dengesizlik Deney Tasarımı

- ▶ Aynı RF modeli altında iki değişkenin etkisi incelenmiştir:
 - ▶ Öznitelik sayısı: Top-50 / Top-100 / Top-200
 - ▶ Dengesizlik stratejisi: sınıf ağırlıkları vs. undersampling
- ▶ Senaryolar:
 - ▶ **CW-50 / CW-100 / CW-200**: `class_weight="balanced"` ile üç farklı öznitelik seti.
 - ▶ **US-200**: Sadece eğitim setinde rastgele undersampling + Top-200 öznitelik.
- ▶ Olasılıksal çıktılar için sınıf bazlı eşikler, F1 skorunu maksimize edecek şekilde 0.01 aralıklarla taranmıştır.

- ▶ Tüm analiz ve deneyler Python 3 ortamında, açık kaynak kütüphaneler kullanılarak gerçekleştirilmiştir.
- ▶ Bağımlılıklar `requirements.txt` ile yönetilmiştir: `pandas`, `numpy`, `scikit-learn`, `matplotlib`, `seaborn`.
- ▶ Deney akışı modülerleştirilmiştir: ön işleme hattı (`preprocessing/pipeline.py`), model eğitimi ve metrik/çizimler (`training/train_models.py`), makale figürleri (`figures/generate_figures.py`).
- ▶ Kod ve deney çıktıları sürüm kontrolü ile yönetilmiş ve herkese açık repo olarak paylaşılmıştır: github.com/AykutN/PTB-XL-Heart-Anomaly-Diagnosis-Project

- ▶ RF + Top-50: Accuracy %55.33, Precision %67.64, Recall %76.53, F1 %71.53, ROC-AUC 0.904.
- ▶ RF + Top-100: Accuracy %58.43, Precision %71.29, Recall %73.68, F1 %72.39, ROC-AUC 0.909.
- ▶ RF + Top-200: Accuracy %58.85, Precision %71.30, Recall %75.60, F1 %73.21, ROC-AUC 0.915.
- ▶ RF + Top-200 + Ensemble: Recall artarken (yaklaşık %78.6), doğruluk ve precision bir miktar düşmüş; F1 kazancı sınırlı kalmıştır.


- ▶ Top-50'den Top-200'e geçiş, Accuracy ve F1 metriklerinde artış sağlamıştır.
- ▶ ROC-AUC tüm senaryolarda 0.90 üzerinde, Top-200 ile 0.915 seviyesine ulaşmaktadır.
- ▶ Bu sonuç, PTB-XL+'ın sayısal EKG özniteliklerinin sınıfları ayırma gücünün yüksek olduğunu göstermektedir.

Sınıf Bazlı Sonuçlar (CW-200)

- ▶ NORM: Eşik 0.30; Precision %79.27, Recall %92.11, F1 %85.21.
- ▶ MI: Eşik 0.45; Precision %74.91, Recall %72.73, F1 %73.80.
- ▶ STTC: Eşik 0.46; Precision %69.24, Recall %79.08, F1 %73.84.
- ▶ CD: Eşik 0.45; Precision %76.87, Recall %70.36, F1 %73.47.
- ▶ HYP: Eşik 0.43; Precision %56.23, Recall %63.74, F1 daha düşük seviyededir.

- ▶ ROC eğrileri tüm sınıflar için yüksek ayrıştırma gücü göstermektedir:
 - ▶ NORM: AUC 0.938
 - ▶ MI: AUC 0.923
 - ▶ STTC: AUC 0.929
 - ▶ CD: AUC 0.901
 - ▶ HYP: AUC 0.883
- ▶ HYP diğer sınıflara göre daha zor bir sınıftır; buna rağmen AUC'nin 0.88 üzerinde olması genel ayrıştırma kapasitesinin güçlü olduğunu göstermektedir.

Figür 5: ROC Eğrileri (Random Forest - Top-200)



- ▶ PTB-XL+ veri seti üzerinde 5 üst sınıf (NORM, MI, STTC, CD, HYP) için RF tabanlı bir sınıflandırma hattı kurulmuştur.
- ▶ Eksik verilerin rastgele dağılmadığı, özellikle P dalgası ile ilgili özniteliklerde MI ve STTC'de yoğunlaştığı görülmüş; bu nedenle eksiklik, *bilgi taşıyan* bir durum olarak modele dahil edilmiştir.
- ▶ Öznitelik sayısının artması genel olarak performansı iyileştirmiş; ROC-AUC değerleri 0.90+ bandında seyretmiştir.
- ▶ Undersampling, recall değerlerini artırsa da precision ve accuracy'de azalmaya yol açmış; sınıf ağırlıkları daha dengeli bir davranış sunmuştur.

Sınıf Bazlı Değerlendirme ve Sınırlılıklar

- ▶ NORM sınıfında yüksek recall elde edilirken, MI ve STTC sınıflarında dengeli F1 değerleri gözlenmiştir.
- ▶ HYP en zor sınıf olup, hem sınıf örnek sayısının azlığı hem de diğer anomali örüntüleriyle örtüşmesi nedeniyle daha düşük metrikler üretmektedir.
- ▶ Çalışmanın sınırlılıkları:
 - ▶ Sınıf dengesizliği yalnızca sınıf ağırlıkları ve basit undersampling ile ele alınmıştır.
 - ▶ Olasılık kalibrasyonu ve karar eşiklerinin klinik hedeflere göre optimize edilmesi detaylı incelenmemiştir.
 - ▶ RF önem skorları belirli yanlılıklara açık olabilir; Top-N kümelerin stabilitesi farklı tohumlarla ayrıca analiz edilebilir.

- ▶ RF yerine veya yanında XGBoost/LightGBM gibi gradient boosting yöntemlerinin denenmesi.
- ▶ Dengesizliğe duyarlı topluluk yöntemleri: Balanced Random Forest, EasyEnsemble vb.
- ▶ Sınıf bazlı eşiklerin, olasılık kalibrasyonu (sigmoid/isotonic) ve klinik kısıtlar (ör. minimum HYP recall) ile birlikte optimize edilmesi.
- ▶ HYP performansını artırmak için alt sınıf (ör. LVH/RVH) düzeyinde daha homojen etiketleme ve ek vektörkardiyografik özniteliklerin değerlendirilmesi.

- [1] P. Wagner, N. Strodthoff, R.-D. Bousseljot, D. Kreiseler, F. I. Lunze, W. Samek, T. Schaeffter, *PTB-XL, a large publicly available electrocardiography dataset*, Scientific Data, 7, 154 (2020).
<https://doi.org/10.1038/s41597-020-0495-6>
- [2] P. Wagner, T. Mehari, N. Strodthoff, et al., *PTB-XL+, a comprehensive electrocardiographic feature dataset*, Scientific Data (2023). <https://doi.org/10.1038/s41597-023-02153-8>
- [3] N. Strodthoff, P. Wagner, T. Schaeffter, W. Samek, *Deep learning for ECG analysis: Benchmarks and insights from PTB-XL*, arXiv preprint arXiv:2004.13701 (2020). <https://arxiv.org/abs/2004.13701>
- [4] L. Breiman, *Random forests*, Machine Learning, 45(1), 5–32 (2001).
<https://doi.org/10.1023/A:1010933404324>
- [5] I. Guyon, A. Elisseeff, *An introduction to variable and feature selection*, Journal of Machine Learning Research, 3, 1157–1182 (2003).
- [6] I. T. Jolliffe, J. Cadima, *Principal component analysis: A review and recent developments*, Philosophical Transactions of the Royal Society A, 374(2065), 20150202 (2016).
- [7] C. Strobl, A.-L. Boulesteix, A. Zeileis, T. Hothorn, *Bias in random forest variable importance measures: Illustrations, sources and a solution*, BMC Bioinformatics, 8, 25 (2007).
<https://doi.org/10.1186/1471-2105-8-25>

- [8] D. B. Rubin, *Inference and missing data*, Biometrika, 63(3), 581–592 (1976).
<https://doi.org/10.1093/biomet/63.3.581>
- [9] J. A. C. Sterne, I. R. White, J. B. Carlin, M. Spratt, P. Royston, M. G. Kenward, J. R. Carpenter, *Multiple imputation for missing data in epidemiological and clinical research: Potential and pitfalls*, BMJ, 338, b2393 (2009). <https://doi.org/10.1136/bmj.b2393>

Sorularınız için teşekkür ederiz.

